

数理统计

$$\text{try: } P(x_l | y_l) = \frac{P(y_l | x_l)P(x_l)}{P(y_l)}$$

Drownm Genius *Drownm Genius* *Drownm Genius*

参考

1. 韦来生《数理统计》
2. 茆诗松《概率论与数理统计》
3. Casella《统计推断》
4. 本人上个学期的概率论笔记《keep random》
5. slides
 1. stat Chapter1.pdf
 2. stat Chapter 2_New.pdf
 3. stat Chapter3.pdf
 4. stat Chapter 4.pdf
 5. stat Chapter 5-final.pdf

统计量分布的推导

前置概率论知识

- 随机变量商的密度函数

$$Z = \frac{X}{Y}, f_z(z) = \int_{-\infty}^{+\infty} f(yz, y)|y|dy$$

- Gamma 分布

$$\begin{aligned} f_{\Gamma(n, \lambda)}(x) &= \frac{\lambda^n}{\Gamma(n)} x^{n-1} e^{-\lambda x} \\ f_{\Gamma(1/2, 1/2)}(x) &= \frac{1}{\sqrt{2\pi}} x^{-1/2} e^{-\frac{1}{2}x} \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi} \\ E(x) &= \frac{n}{\lambda} \quad Var(x) = \frac{n}{\lambda^2} \end{aligned}$$

- Definition: $\Gamma(z) = \int_0^\infty x^{z-1} e^{-x} dx$.
- $\Gamma(z+1) = z\Gamma(z)$, $\Gamma(1) = 1$, $\Gamma(n) = (n-1)!$ for n be a positive integer.
- $\Gamma(1/2) = \sqrt{\pi}$, $\Gamma(3/2) = \frac{1}{2}\sqrt{\pi}$, $\Gamma(-1/2) = -2\sqrt{\pi}$.
- $\Gamma(\frac{1}{2} + n) = \frac{(2n-1)!!}{2^n} \sqrt{\pi}$, $\Gamma(\frac{1}{2} - n) = \frac{(-1)^n 2^n}{(2n-1)!!} \sqrt{\pi}$, $\lim_{n \rightarrow \infty} \frac{\Gamma(n+\alpha)}{\Gamma(n) \cdot n^\alpha} = 1$.
- For any two positive real numbers x_1 and x_2 , and for any $t \in [0, 1]$, we have

$$\Gamma(tx_1 + (1-t)x_2) \leq \Gamma^t(x_1) \Gamma^{1-t}(x_2).$$

- 随机变量、随机向量函数的分布
- 多元正态分布
[多元统计分析（二）：多元正态分布 - 知乎 \(zhihu.com\)](#)
主要内容：多元正态分布的表示，多元正态分布线性变换，多元正态导出 χ^2 分布
- 特征函数、数量特征
[概率论中常见分布的数学期望、方差及其特征函数推导——连续性随机变量 - 知乎 \(zhihu.com\)](#)
- 其他
[数理统计第二讲（经验分布函数，格里文科定理，统计量） - 知乎](#)

次序统计量

联合分布

$$f(x_{(1)} \dots x_{(n)}) = n! f(X_1 \dots X_n) \mathbb{1}_{X_1 < \dots < X_n} \stackrel{i.i.d}{=} n! (f(X))^n \mathbb{1}_{X_1 < \dots < X_n}$$

边缘分布

$$1 - F(x_{(1)}) \stackrel{i.i.d}{=} (1 - F(x))^n \rightarrow f(x_{(1)}) = n(1 - F(x))^{n-1}f(x)$$

$$F(x_{(n)}) \stackrel{i.i.d}{=} (F(x))^n \rightarrow f(x_{(n)}) = n(F(x))^{n-1}f(x)$$

$$F(x_{(m)} : \text{至少有 } m \text{ 个样本小于 } x) = \sum_{i=m}^n C_n^i (F(x))^i (1 - F(x))^{n-i}$$

$$\rightarrow f(x_{(m)}) = \frac{n!}{(n-m)!(m-1)!} F(x)^{m-1} (1 - F(x))^{n-m} f(x)$$

$$F(x_{(i)} = x, x_{(j)} = y, (i < j) : \text{至少有 } i \text{ 个样本小于 } x, j \text{ 个样本大于 } x)$$

$$= \sum_{k=i}^n C_n^k (F(x))^k (1 - F(x))^{n-k} \sum_{m=j}^n C_n^m (F(y))^{n-m} (1 - F(y))^m$$

$$f_{ij}(x, y) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} F(x)^{i-1} (F(y)F(x))^{j-i-1} (1 - F(y))^{n-j} f(x)f(y)$$

极差分布

正态总体相关分布

正态样本统计量的分布(\bar{X} S^2)

★ 对于服从正态分布的简单随机样本 $X_1 \cdots X_n, X_i \sim N(a, \sigma^2)$ 的样本均值 \bar{X} 和样本方差 S^2 ，我们有以下结论：

1. $\bar{X} \sim N(a, \sigma^2/n)$ i.e. $\sqrt{n} \frac{(\bar{X}-a)}{\sigma} \sim N(0, 1) : Z \text{ statistic}$
2. $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$
3. \bar{X} 与 S^2 不相关

证明：后两个命题证明考虑正交变换 $Y = AX$ Y 与 X 的分布一样，仅仅做了旋转变换

$$A = \begin{pmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

Let $A = \begin{pmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$, which satisfies $AA^T = A^T A = I$.
Denote $Y = AX$, then we have:

$$Y_1 = \frac{1}{\sqrt{n}} \sum_{i=1}^n X_i = \sqrt{n}\bar{X} \text{ and } Y_1^2 + \dots + Y_n^2 = X_1^2 + \dots + X_n^2$$

as $\text{tr}(Y^T Y) = \text{tr}(X^T A^T A X) = \text{tr}(X^T X)$ such that

$$\begin{aligned} (n-1)S^2 &= \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 \\ &= \sum_{i=1}^n Y_i^2 - Y_1^2 = \sum_{i=2}^n Y_i^2. \end{aligned}$$

- From Theorem 2, we have Y_1, \dots, Y_n are independent, and $Y_i \sim N(\mu_i, \sigma^2)$.

- And

$$\mu_i = a \sum_{k=1}^n a_{ik} = a\sqrt{n} \sum_{k=1}^n \frac{1}{\sqrt{n}} \cdot a_{ik} = a\sqrt{n} A(i, :) A(1, :)^T = 0$$

for $i = 2, \dots, n$ as $AA^T = I$.

- $Y_2, \dots, Y_n \sim N(0, \sigma^2)$ such that $Y_2/\sigma, \dots, Y_n/\sigma \sim N(0, 1)$.

统计学三大分布($\chi^2 \rightarrow t . F$)

• χ^2 分布

- 定义：记 $X_1 \cdots X_n \stackrel{i.i.d}{\sim} N(0, 1)$, 则 $\sum_{i=1}^n X_i^2 \sim \chi_n^2$: 自由度为n的卡方分布
- 来源：若 $X \sim N(0, 1)$, 则 $X^2 \sim \Gamma(\frac{1}{2}, \frac{1}{2})$. 由于Gamma分布具有独立可加性, 所以 $\sum_{i=1}^n X_i^2 \sim \Gamma(\frac{n}{2}, \frac{1}{2})$ i.e. χ_n^2
 - $\Gamma(\frac{1}{2}, \frac{1}{2})$ 的证明：由换元法求pdf可知 X^2 的分布函数：

$$f_{\chi^2}(x) = 2\phi(\sqrt{x}) \left| \frac{1}{2\sqrt{x}} \right| = \frac{e^{-\frac{x}{2}}}{\sqrt{2\pi x}} \sim \Gamma(\frac{1}{2}, \frac{1}{2}), \text{ since } \Gamma(\frac{1}{2}) = \sqrt{\pi}$$
 - 可加性的证明：卷积+归纳法
 - 可加性的来源： $\Gamma(k, \theta)$ 分布可以视为k个i.i.d $\sim \text{Exp}(\theta)$ 的和
 - 证明：特征函数
 - 总结：指数分布 $\text{Exp}(\lambda)$ 的独立和:伽马分布 $\Gamma(n, \lambda) \rightarrow \Gamma(1/2, 1/2)$ 独立和:卡方分布 \rightarrow 卡方分布独立和极限:正态分布
 - Gamma分布可加性可以推广到非整数, 但是 $\Gamma(k_1, \theta_1), \Gamma(k_2, \theta_2)$ 要满足等比例条件: [Gamma分布的可加性到底应该如何证明?](#)

[知乎 \(zhihu.com\)](https://www.zhihu.com)

- 推论(从**指数分布构造卡方分布**): 如果 $X_1 \cdots X_n$ 独立,
 $X_i \sim \text{Exp}(\lambda_i)$, 则 $\sum_{i=1}^n 2\lambda_i X_i \sim \chi_{2n}^2$
 - $2\lambda_i X_i$ 的pdf是 $\frac{1}{2}e^{-\frac{y}{2}} \sim \chi_2^2 = \Gamma(1, \frac{1}{2})$
 - χ^2 可加性

- **t分布**

- 定义: 记 $Y \sim \chi_n^2, X \sim N(0, 1)$, X, Y 相互独立, $T = \frac{X}{\sqrt{Y/n}} \sim t_n$ 自由度为n的t分布

- **F分布**

- 定义: 记 $Y \sim \chi_n^2, X \sim \chi_m^2$; X, Y 相互独立: $F = \frac{X/m}{Y/n} \sim F_{m,n}$: 自由度为m和n的F分布

- **性质**

- $t \sim t_n \rightarrow t^2 \sim F_{(1,n)}$
- 两个独立正态随机变量的比 $\frac{X}{Y} \sim t_1 \sim \text{Standard Cauchy}$
- $Z \sim F_{(m,n)} \rightarrow 1/Z \sim F_{(n,m)}$
- $F_{(m,n)}(\alpha) = F_{(n,m)}(1 - \alpha)$

$$\begin{aligned}\alpha &= P(Z < F_{(m,n)}(\alpha)) \\ &= P(1/Z > 1/F_{(m,n)}(\alpha)) \\ &= P(1/Z < F_{(n,m)}(1 - \alpha))\end{aligned}$$

推论:

- Lemma 1: Assume $X_1, \dots, X_n \text{ i.i.d. } \sim N(a, \sigma^2)$, then

$$T = \frac{\sqrt{n}(\bar{X} - a)}{S} \sim t_{n-1}.$$

Proof: We have $\sqrt{n}(\bar{X} - a)/\sigma \sim N(0, 1)$ and $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$.

- Lemma 2: Assume $X_1, \dots, X_m \text{ i.i.d. } \sim N(a_1, \sigma^2)$, $Y_1, \dots, Y_n \text{ i.i.d. } \sim N(a_2, \sigma^2)$, and $X_1, \dots, X_m; Y_1, \dots, Y_n$ are independent, then

$$T = \frac{(\bar{X} - \bar{Y}) - (a_1 - a_2)}{S_w} \cdot \sqrt{\frac{mn}{m+n}} \sim t_{n+m-2},$$

where $(n+m-2)S_w^2 = \sum_{i=1}^m (X_i - \bar{X})^2 + \sum_{j=1}^n (Y_j - \bar{Y})^2$.

Proof: We have $\bar{X} \sim N(a_1, \sigma^2/m)$ and $\bar{Y} \sim N(a_2, \sigma^2/n)$ such that $\bar{X} - \bar{Y} \sim N(a_1 - a_2, \frac{m+n}{mn}\sigma^2)$.

- Lemma 3: Assume $X_1, \dots, X_m \text{ i.i.d. } \sim N(a_1, \sigma_1^2)$, $Y_1, \dots, Y_n \text{ i.i.d. } \sim N(a_2, \sigma_2^2)$, and $X_1, \dots, X_m; Y_1, \dots, Y_n$ are independent, then

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{m-1, n-1}.$$

Proof: We have $(m-1)S_1^2/\sigma_1^2 \sim \chi_{m-1}^2$ and $(n-1)S_2^2/\sigma_2^2 \sim \chi_{n-1}^2$.

统计量的极限分布

几类收敛(to be filled) LLN CLT

[概率论——大数定律与中心极限定理 - 知乎 \(zhihu.com\)](https://zhuanlan.zhihu.com/p/111111111)

指数分布族

指数分布族(指数可以视为一个参数空间的向量和样本空间的向量的内积:

$$Q(\theta)'T(X)$$

注意: 指数分布-Gamma分布- χ^2 分布; 两点分布-二项分布-Poisson分布; 正态分布都属于指数族; 但是均匀分布不属于指数族!

$$f(x, \theta) = C(\theta) \exp \left\{ \sum_{i=1}^k Q_i(\theta) T_i(x) \right\} h(x),$$

指数分布族的自然形式(本质就是把上个式子换个元: $\theta_{natural} = Q_i(\theta)$)

$$f(x, \theta) = C^*(\theta) \exp \left\{ \sum_{i=1}^k \theta_i T_i(x) \right\} h(x),$$

由此可以引出自然参数空间(通过Hölder不等式可以证明是一个凸集)

$$\Theta^* = \left\{ (\theta_1, \dots, \theta_k) : \int_{\mathcal{X}} \exp \left\{ \sum_{i=1}^k \theta_i T_i(x) \right\} h(x) dx < \infty \right\}.$$

赫尔德不等式: 设 $p > 1$, $\frac{1}{p} + \frac{1}{q} = 1$, 如果 $f \in L^p(\Omega)$, $g \in L^q(\Omega)$, 那么

$$\int_{\Omega} f(x)g(x)dx \leq \left(\int_{\Omega} |f(x)|^p dx \right)^{\frac{1}{p}} \left(\int_{\Omega} |g(x)|^q dx \right)^{\frac{1}{q}}$$

$$\Omega = \left\{ w = (w_1, \dots, w_k) : \int_{\mathcal{X}} \exp \left\{ \sum_{j=1}^k w_j T_j(x) \right\} d\mu_1(x) < \infty \right\}$$

其中 $d\mu_1(x) = h(x) d\mu(x)$, 设 $w' = (w'_1, \dots, w'_k)$, $w'' = (w''_1, \dots, w''_k) \in \Omega$, 又设 $0 < \alpha < 1$, 往证 $w = \alpha w' + (1 - \alpha) w'' = (w_1, \dots, w_k) \in \Omega$ 事实上

$$\begin{aligned} & \int_{\mathcal{X}} \exp \left\{ \sum_{j=1}^k w_j T_j(x) \right\} d\mu_1(x) \\ &= \int_{\mathcal{X}} \left[\exp \left\{ \sum_{j=1}^k w'_j T_j(x) \right\} \right]^{\alpha} \left[\exp \left\{ \sum_{j=1}^k w''_j T_j(x) \right\} \right]^{1-\alpha} d\mu_1(x) \\ &\leq \left[\int_{\mathcal{X}} \exp \left\{ \sum_{j=1}^k w'_j T_j(x) \right\} d\mu_1(x) \right]^{\alpha} \left[\int_{\mathcal{X}} \exp \left\{ \sum_{j=1}^k w''_j T_j(x) \right\} d\mu_1(x) \right]^{1-\alpha} \end{aligned}$$

最后一个不等式是采用了 Hölder 不等式, 由于 $w', w'' \in \Omega$, 所以不等式右边两个因子中的积分存在, 从而得到 $w \in \Omega$, 这说明了 Ω 是凸集, 证毕.

几个常见分布的指数族形式

正态(可以发现指数族的判定与样本容量无关)

$$\begin{aligned} f(x, \theta) &= (\sqrt{2\pi n})^{-n} \exp \left(-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \right) \\ &= (\sqrt{2\pi n})^{-n} \exp \left(-\frac{n\mu^2}{2\sigma^2} \right) \exp \left(\frac{\mu}{\sigma^2} \sum x_i - \frac{1}{2\sigma^2} \sum x_i^2 \right) \end{aligned}$$

正态分布自然参数空间:

$$\left\{ \left(\phi_1(x) = \frac{\mu}{\sigma^2}, \phi_2(x) = -\frac{1}{2\sigma^2} \right), \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}^+ \right\} = \{(\phi_1, \phi_2) : \phi_1 \in \mathbb{R}, \phi_2 < 0\}$$

指数

$$\begin{aligned} f(x, \theta) &= \prod (\lambda e^{-\lambda x_i} \mathbb{1}_{(0, \infty)}(x_i)) \\ &= \lambda^n \exp \left(-\lambda \sum x_i \right) \prod \mathbb{1}_{(0, \infty)}(x_i) \end{aligned}$$

指数分布自然参数空间: $\{-\lambda\} = (-\infty, 0)$

Gamma (γ, λ) γ 已知

$$\begin{aligned} f(x, \theta) &= \prod \left(\frac{\lambda^\gamma}{\Gamma(\gamma)} x_i^{\gamma-1} e^{-\lambda x_i} \mathbb{1}_{(0, \infty)}(x_i) \right) \\ &= \frac{\lambda^{n\gamma}}{\Gamma(\gamma)^n} \exp \left(-\lambda \sum x_i \right) \prod x_i^{\gamma-1} \mathbb{1}_{(0, \infty)}(x_i) \end{aligned}$$

Gamma (γ, λ) 分布自然参数空间: $\{-\lambda\} = (-\infty, 0)$

两点分布 $b(1, p)$

$$\begin{aligned} f(x, \theta) &= p^{\sum x_i} (1-p)^{n-\sum x_i} \\ &= (1-p)^n \left(\frac{p}{1-p} \right)^{\sum x_i} \\ &= (1-p)^n \exp \left(\ln \left(\frac{p}{1-p} \right) \sum x_i \right) \end{aligned}$$

两点分布 $b(1, p)$ 自然参数空间: $\left\{ \ln \left(\frac{p}{1-p} \right), p \in (0, 1) \right\} = \mathbb{R}$

泊松 Poisson (λ)

$$\begin{aligned} F(X, \theta) &= \frac{e^{-n\lambda}}{\prod (x_i)!} \lambda^{\sum x_i} \\ &= e^{-n\lambda} \exp \left(\ln(\lambda) \sum x_i \right) \frac{1}{\prod (x_i)!} \end{aligned}$$

泊松 Poisson (λ) 分布自然参数空间: $\{\ln(\lambda), \lambda \in \mathbb{R}\} = \mathbb{R}$

指数族的性质

1. 如果一族分布属于指数族，那么ta的分布函数的支撑集与 θ 无关：

$$\{x : f(x) > 0\} = \{x : h(x) > 0\}$$

通过这一性质(必要条件)可以看出均匀分布不是指数族：支撑集与区间参数 θ 相关

统计量的几个性质

充分统计量 s.s.

Definition: If the conditional distribution $P_\theta(\mathbf{X} \in A | T(\mathbf{X}) = t)$ does not depend on θ for any Borel set A , then $T(\mathbf{X})$ is a sufficient statistic.

idea: 统计量 $T(X)$ 包含了关于参数 θ 的全部信息，即：如果两个样本 X, Y 满足 $T(X) = T(Y)$ 那么依据这两个样本关于参数 θ 的信息是一样的

判别s. s. 的**充要条件**：因式分解定理——统计量分布函数可以因式分解到以下形式

$$f(x, \theta) = g(t(x), \theta)h(x),$$

例子：对于从任意一维分布族 \mathcal{F} 中的一个总体 F 抽出的一组样本 X ，其对应的次序统计量 $T(X) = (T_{(1)}(X) \cdots T_{(n)}(X))$ 是s. s.

因为样本的联合分布pdf总可以写成

$$f(x_1 \cdots x_n) = f(x_{(1)}) \cdots f(x_{(n)}) = g(T(X), \theta)h(X), h(X) \equiv 1$$

根据因式分解定理，可以证明 $T(X)$ 是s. s.

引理：对充分统计量 $T(X)$ 的可逆映射的像 $\phi(T)$ 也是s. s.

最小充分统计量 minimal s.s.

此处的最小指的是映射关系：每一次映射过程造成了信息的减少/至多不变。

$$\sigma_T \subset \sigma_S$$

Minimal Sufficient Statistic— Assume T is a sufficient statistic of distribution family \mathcal{F} . If for any sufficient statistic $S(\mathbf{X})$, there always exist a function $q_S(\cdot)$ such that $T(\mathbf{X}) = q_S(S(\mathbf{X}))$, then we call $T(\mathbf{X})$ the minimal sufficient statistic of \mathcal{F} .

完全统计量 c.s.

idea: 在 $\text{span}(T)$ 中, 零无偏估计量只有0本身

Definition: Assume $\mathcal{F} = \{f(x, \theta), \theta \in \Theta\}$ is a distribution family. Θ is the parameter space. Assume $T = T(X)$ is a statistic, if for any $\varphi(T(X))$ which satisfies

$$E_{\theta} \varphi(T(X)) = 0 \text{ for any } \theta \in \Theta,$$

then

$$P(\varphi(T(X)) = 0) = 1 \text{ for any } \theta \in \Theta.$$

We call $T(X)$ a complete statistic (CS) of θ .

定理: 对于**指数分布族**, 只要**变形后得到的自然参数空间有内点**, 则变形后得到的 $T(X)$ 就是 c. s. s.

Theorem: Assume the density of $\mathbf{X} = (X_1, \dots, X_n)^T$ is

$$f(\mathbf{x}, \boldsymbol{\theta}) = C(\boldsymbol{\theta}) \exp \left\{ \sum_{i=1}^k \theta_i T_i(\mathbf{x}) \right\} h(\mathbf{x}), \quad \boldsymbol{\theta} = (\theta_1, \dots, \theta_k)^T \in \Theta^*.$$

Let $T(\mathbf{X}) = (T_1(\mathbf{X}), \dots, T_k(\mathbf{X}))^T$. If there are some inner points in $\Theta^* \in R^k$, then $T(\mathbf{X})$ is a complete statistic.

引理: 对 c. s. s. $T(X)$ 的可逆映射的像 $\phi(T)$ 也是 c. s. s.

Basu 定理

[使用Basu定理的题目 - 知乎 \(zhihu.com\)](#)

简述: **有界完备充分统计量(bounded c.s.s.)与辅助统计量(分布与参数无关)独立**, 对于任意 $\theta \in \Theta$

- Definition: We call $T(X)$ a **bounded complete statistic** if for any bounded or almost bounded everywhere function $\varphi(\cdot)$ which satisfies

$$E_{\theta} \varphi(T(X)) = 0 \text{ for any } \theta \in \Theta,$$

then $P(\varphi(T(X)) = 0) = 1$ for any $\theta \in \Theta$ is true.

- (**Basu Theorem**) Assume $\mathcal{F} = \{F_{\theta}(x), \theta \in \Theta\}$ is a distribution family, $\mathbf{X} = (X_1, \dots, X_n)^T$ is a simple random sample selected from \mathcal{F} . $T(\mathbf{X})$ is a **bounded complete statistic and sufficient statistic**. If the distribution of random variable $V(\mathbf{X})$ does not depend on θ , then for any $\theta \in \Theta$, $V(\mathbf{X})$ and $T(\mathbf{X})$ are independent.

引理: 自然参数形式的指数分布族之中对于Basu定理的应用

- Lemma: Assume the density of $\mathbf{X} = (X_1, \dots, X_n)^T$ is

$$f(\mathbf{x}, \boldsymbol{\theta}) = C(\boldsymbol{\theta}) \exp \left\{ \sum_{i=1}^k \theta_i T_i(\mathbf{x}) \right\} h(\mathbf{x}) \quad \boldsymbol{\theta} = (\theta_1, \dots, \theta_k)^T \in \Theta^*.$$

Let $T(\mathbf{X}) = (T_1(\mathbf{X}), \dots, T_k(\mathbf{X}))^T$. If the distribution of random variable $V(\mathbf{X})$ does not depend on θ , then for any $\theta \in \Theta$, $V(\mathbf{X})$ and $T(\mathbf{X})$ are independent.

解题思路总结

- 首先给出样本联合条件分布函数
- 将其因式分解(根据因式分解定理得到s. s.)
- 证明完备(恒成立证明)

- 进一步设定零条件期望函数，写出期望表达式
 - 通过求导等手段证其恒为0，得到c. s. s.
- 对于指数族：直接分解到自然形式的指数族得到c. s. s.
- 证明不完备(存在性证明)
 - 构造不恒为零的零条件期望函数
- 利用Basu定理证明有界完备s. s. 与辅助统计量独立

点估计

描述点估计量的几个性质

无偏性 unbiased

$$E(\hat{g}(X)) = g(\theta) \quad \text{for any } \theta \in \Theta \quad \text{无偏}$$

$$\lim_{n \rightarrow \infty} E(\hat{g}_n(X)) = g(\theta) \quad \text{for any } \theta \in \Theta \quad \text{渐近无偏}$$

有效性 efficient

对于无偏估计 $\hat{g}(X), \tilde{g}(X)$

$$D_{\theta} \hat{g}(X) \leq D_{\theta} \tilde{g}(X) \quad \text{for any } \theta \in \Theta$$

$$D_{\theta} \hat{g}(X) < D_{\theta} \tilde{g}(X) \quad \text{for some } \theta \in \Theta$$

一致性/相合性 consistent

$$\lim_{n \rightarrow \infty} P_{\theta}(|\hat{g}_n(X) - g(\theta)| \geq \epsilon) = 0 \quad \text{for any } \theta \in \Theta \quad \text{strong consistency}$$

$$P_{\theta}(\lim_{n \rightarrow \infty} \hat{g}_n(X) = g(\theta)) = 1 \quad \text{for any } \theta \in \Theta \quad \text{weak consistency}$$

$$\lim_{n \rightarrow \infty} E_{\theta}(|\hat{g}_n(X) - g(\theta)|)^r = 0 \quad \text{for any } \theta \in \Theta \quad r^{\text{th}} \text{ mean consistency}$$

一致渐进正态估计 CAN

Slutsky引理


对于r. v.序列 $\{X_n\}, \{Y_n\}$: 如果 $X_n \xrightarrow{\mathcal{D}} X, Y_n \xrightarrow{P} c$, 那么:

$$X_n \pm Y_n \xrightarrow{\mathcal{D}} X \pm c \quad X_n \cdot Y_n \xrightarrow{\mathcal{D}} cX \quad \frac{X_n}{Y_n} \xrightarrow{\mathcal{D}} \frac{X}{c}$$

矩法(MM)

本质就是将要估计的 $g(\theta)$ 用总体的各阶矩(中心矩、原点矩)表示 $g(\theta) = g(\alpha, \mu)$ ，然后对应的矩估计量就是换成对应的样本矩 $g(\hat{\alpha}, \hat{\mu})$

性质

1. 依据“原点样本矩是无偏的；中心样本矩是渐进无偏的”可以判断矩估计量的无偏性
2. 依据“点样本矩、中心样本矩是强相合估计”可以判断矩估计量的相合性
 1. 定理：a. s. 收敛的r. v. 经过连续变换后依旧a. s. 收敛；注意原点矩可以视为原点矩的连续映射的像，应用此定理可以证明其强相合性
3.  CAN(一致渐近正态分布)

极大似然估计(MLE)

本质是**基于已获得样本**的联合条件分布(似然函数)的值推断总体参数取值(样本取自哪一个总体)的可能性(似然性)大小：这个值越大，样本取自该总体的可能性越高。

求法

先求样本的联合分布函数

如果**关于参数可微**，那么就用微积分的方法求解(出于计算方便，我们一般以对数似然函数为目标函数)，得到的方程可以解出 $\hat{\theta}(X)_{MLE}$

如果**关于参数不可微**，那就根据定义来分析(e. g. 均匀分布 $U(0, \theta)$ 的MLE是 $X_{(n)}$)

性质

1. 如果总体是指数族，只要似然方程的解是自然参数空间的内点，那么MLE的解唯一
2. MLE总可以表示为s. s. $T(X)$ 的函数：根据**因式分解定理**：
$$L(x, \theta) = \prod f(x_i, \theta) = \prod g(T, \theta)h(x_i),$$
对 θ 的优化集中在 $g(T, \theta)$ 中。

估计效果的评价, UMVUE

解释：U-一致(对于全体 θ)；MV-最小方差；UE-无偏估计(可估的)

为什么用UMVUE?

缩小范围(仅仅考虑无偏估计)为保证存在性。本来是考虑全体统计量取最小MSE者，但是不好求

UE改进

对于任意一个无偏估计 $g(X)$ 若存在一个充分统计量 $T(X)$ 那么有:

$$\begin{aligned} E_{\theta}(h(T)) &= E_{\theta}(E(g(X)|T)) = E_{\theta}(g(X)) = g(\theta) \\ D_{\theta}(h(T) &:= E(g(X)|T(X))) \leq D_{\theta}(g(X)) \end{aligned}$$

等号当且仅当 $g(X) = T(X), a. s.$ 时成立

$$\begin{aligned} D_{\theta}g(X) &= E_{\theta}(g(X) - g(\theta))^2 \\ &= E_{\theta}[(g(X) - h(T)) + (h(T) - g(\theta))]^2 \\ &= E_{\theta}(g(X) - h(T))^2 + 2E_{\theta}(g(X) - h(T))(h(T) - g(\theta)) + D_{\theta}h(T)^2 \\ &= E_{\theta}(g(X) - h(T))^2 + D_{\theta}h(T)^2 \\ &\quad E_{\theta}(g(X) - h(T))(h(T) - g(\theta)) \\ &\quad = E_{\theta}\{E(g(X) - h(T))(h(T) - g(\theta))|T\} \\ &\quad = E_{\theta}\{(h(T) - g(\theta))E(g(X) - h(T)|T)\} \\ &\quad = 0 \end{aligned}$$

UMVUE 判别

零无偏准则

idea:对于任意一个无偏估计 $g(X)$ ，我们似乎总可以插入一些“零无偏的噪声” ϵ 使得估计的效果变差；但如果有一个无偏估计 $g(X)^*$ 对于各种噪声都是免疫的：插入任何噪声都不会影响ta的估计效(用方差衡量的话)，那么ta自然就是一个UMVUE。这种“免疫性”用数学表示就是

$$\text{Cov}_{\theta}(g(X)^*, l(X)) = 0, \forall l(X) : E_{\theta}(l(X)) = 0, \forall \theta$$

★注意，零无偏估计量全体所对应的集合 $\{l(X) : E_{\theta}l(X) = 0\}$ 是一个线性空间

★这是一个UMVUE判别的充要条件

充分性:

对于任一 $\hat{g}(X)$ 总可以表示成 $g(X)^* + l(X)$ 的形式:

$$\begin{aligned}
D_{\theta}(\hat{g}(X)) &= D_{\theta}(g(X)^* + l(X)) \\
&= D_{\theta}(g(X)^*) + D_{\theta}(l(X)) + 2Cov_{\theta}(g(X)^*, l(X)) \\
&= D_{\theta}(g(X)^*) + D_{\theta}(l(X)) \\
&\geq D_{\theta}(g(X)^*)
\end{aligned}$$

必要性:

反证，如果一个UMVUE: $g(X)$ 与一个零无偏估计量 $l(X)$ 条件协方差不为0, 那么可以构造一个条件方差更小的无偏估计: $g(X)^* = g(X) - al(X)$

$$\begin{aligned}
D_{\theta}(g(X)^*) &= D_{\theta}(g(X) - al(X)) \\
&= D_{\theta}(g(X)) + a^2 D_{\theta}(l(X)) - 2aCov_{\theta}(g(X), l(X)) \\
&\leq D_{\theta}(g(X)) \iff a^2 D_{\theta}(l(X)) - 2aCov_{\theta}(g(X), l(X)) \leq 0
\end{aligned}$$

由此，我们总可以找到一个满足条件的 a 得到一个更有效的无偏估计，与UMVUE条件矛盾。所以零无偏条件成立

如果我们现在知道一个充分统计量 $T(X)$ ，那么我们可以把视角放在 $\text{span}(T)$ 上面，因为我们总可以借助 $T(X)$ 优化无偏估计 $g(X)$ 。此时零无偏条件变为:

$$Cov_{\theta}(h(T)^*, \delta(T)) = 0, \forall \delta(T) : E_{\theta}(\delta(T)) = 0, \forall \theta$$

c.s.s.方法, L-S定理


如果我们已知一个c. s. s. $T(X)$ 那么我们可以证明从 ta 映射出的无偏估计量是**唯一的UMVUE** (e. g. 我们得到了一个无偏估计 $g(X)$, 那么 $h(T) = E(g(X)|T)$ 就是唯一的UMVUE)

★ 这是一个基于c. c. s. 的UMVUE判别的充分条件

最小方差: 对于任一个无偏估计 $g(X)$, 总可以通过s. s. $T(X)$ 优化

$$h(T) = E(g(X)|T)$$

唯一性: 从c. s. 的性质出发: 对于 $\text{span}(T)$ 中的两个无偏估计 $\tilde{g}(X), \hat{g}(X)$, ta 们的差是零无偏估计量, 由于 $T(X)$ 是c. s. $\text{span}(T)$ 中零无偏估计量只有0 所以这两个无批判估计在概率层面上相等



证 先证唯一性. 设 $\hat{g}_1(T(\mathbf{X}))$ 为 $g(\theta)$ 的任一无偏估计, 令 $\delta(T(\mathbf{X})) = \hat{g}(T(\mathbf{X})) - \hat{g}_1(T(\mathbf{X}))$, 则 $E_\theta \delta(T(\mathbf{X})) = E_\theta \hat{g}(T(\mathbf{X})) - E_\theta \hat{g}_1(T(\mathbf{X})) = 0, \theta \in \Theta$. 由 $T(\mathbf{X})$ 为完全统计量, 可知 $\delta(T(\mathbf{X})) = 0, \text{a.s. } P_\theta$ 成立, 即 $\hat{g}(T(\mathbf{X})) = \hat{g}_1(T(\mathbf{X})), \text{a.s. } P_\theta$ 成立, 故唯一性成立.

再证一致最小方差性. 设 $\varphi(\mathbf{X})$ 为 $g(\theta)$ 的任一无偏估计. 令 $h(T(\mathbf{X})) = E(\varphi(\mathbf{X})|T)$, 由 $T(\mathbf{X})$ 为充分统计量, 故知 $h(T(\mathbf{X}))$ 与 θ 无关, 是统计量. 由引理 3.4.1 可知

$$E_\theta(h(T(\mathbf{X}))) = g(\theta), \quad \text{一切 } \theta \in \Theta,$$

$$D_\theta(h(T(\mathbf{X}))) \leq D_\theta(\varphi(\mathbf{X})), \quad \text{一切 } \theta \in \Theta.$$

由唯一性得 $\hat{g}(T(\mathbf{X})) = h(T(\mathbf{X})), \text{a.e. } P_\theta$ 成立, 由上式可知

$$D_\theta(\hat{g}(T(\mathbf{X}))) = D_\theta(h(T(\mathbf{X}))) \leq D_\theta(\varphi(\mathbf{X})), \quad \text{一切 } \theta \in \Theta,$$

所以 $\hat{g}(T(\mathbf{X}))$ 为 $g(\theta)$ 的 UMVUE, 且唯一.

估计效果的边界, C-R不等式

$$D_\theta[\hat{g}(X)] \geq \frac{[g'(\theta)]^2}{nI(\theta)}$$

C-R不等式满足的一系列必要条件(**C-R分布族**):

- The parameter space is an open set in R ;
- The support set does not depend on θ ;
- For any $x \in X$ and $\theta \in \Theta$, $\frac{\partial f(x, \theta)}{\partial \theta}$ exists;
- $\frac{\partial}{\partial \theta} \int f(x, \theta) dx = \int \frac{\partial}{\partial \theta} f(x, \theta) dx$;
- The fisher information $I(\theta) = E_{\theta} \left[\frac{\partial \log f(X, \theta)}{\partial \theta} \right]^2$ exists and $0 < I(\theta) = E_{\theta} \left[\frac{\partial \log f(X, \theta)}{\partial \theta} \right]^2 < \infty$.

C-R不等式**完整内容**:

Theorem: Assume $\mathcal{F} = \{f(x, \theta), \theta \in \Theta\}$ be a C-R distribution family. $g(\theta)$ is defined on Θ . Assume $\mathbf{X} = (X_1, \dots, X_n)$ is a simple sample from $f(x, \theta)$, $\hat{g}(\mathbf{X})$ is an unbiased estimator of $g(\theta)$, and satisfies

$$\int \cdots \int \hat{g}(\mathbf{x}) f(\mathbf{x}, \theta) d\mathbf{x}$$

can be taken derivative under the integration, then

$$D_{\theta}[\hat{g}(\mathbf{X})] \geq \frac{(g'(\theta))^2}{nI(\theta)} \quad \text{for any } \theta \in \Theta.$$

e. g. $g(\theta) = \theta \rightarrow D_{\theta}(\hat{\theta}(X)) \geq \frac{1}{nI(\theta)}$

这个式子表明给定样本，对于总体参数的估计存天然的下限，这一下限与总体分布相关(Fisher信息量)

证明：归根到底还是Cauchy不等式

书上的证明很有趣，但是有点长，理解欣赏就好

区间估计

描述置信区间的性质

1. 置信度：我们用区间估计水平的一致下限：置信系数来表示
def : 区间估计 $[\hat{\theta}_1, \hat{\theta}_2]$ 的置信系数 $= \inf_{\theta \in \Theta} P_{\theta}(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2)$
2. 置信水平 α ：外生给定的；只要一个区间估计的置信度不小于 $1 - \alpha$ ，则可以说ta具有 $1 - \alpha$ 的置信水平的
3. 置信限：当区间估计是单侧的，形如 $(-\infty, \hat{\theta}_1], [\hat{\theta}_2, \infty)$ ，此时也可以给定一个置信水平 α 来定义一个具有 $1 - \alpha$ 的置信水平的置信限
4. 精度：也就是区间的大小(在一维空间上就是长度)

枢轴变量法构造置信区间

Pivotal Variable Method

所谓枢轴变量就是一个r. v. $\phi(T(X), \theta)$ ，其中 $T(X)$ 是对 θ 的一个点估计； $\phi(T(X), \theta)$ 的分布与 θ 无关，从而我们可以依据这一分布来给出一个与 θ 无关的，关于 $\phi(\cdot)$ 具有 $1 - \alpha$ 水平的置信区间；然后再进行变量代换就可以得到关于 θ 的 $1 - \alpha$ 水平的置信区间。

正态总体下的估计

一个正态总体		
待估参数	参数信息	枢轴变量及其分布
μ	σ^2 已知	$\sqrt{n} \frac{\bar{x} - \mu}{\sigma^2} \sim N(0, 1)$
	σ^2 未知	$\sqrt{n} \frac{\bar{x} - \mu}{S^2} \sim t_{n-1}$
σ^2	μ 已知	$\frac{n \sum (x_i - \mu)^2}{\sigma^2} \sim \chi_n^2$
	μ 未知	$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$

两个正态总体 $X \sim N(a, \sigma_1^2), Y \sim N(b, \sigma_2^2)$		
待估参数	样本/参数信息	枢轴变量及其分布
b-a	样本容量一样	设 $Z_i = X_i + Y_i \sim N(b - a, \sigma_1^2 + \sigma_2^2)$
	σ_1^2, σ_2^2 已知	$\bar{Y} - \bar{X} \sim N\left(b - a, \frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}\right)$
	$\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知	$\frac{\bar{Y} - \bar{X} - (b-a)}{S_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t_{m+n-2}$
	其他情况	用大样本CLT近似, Z-stat: $\frac{\bar{Y} - \bar{X} - (b-a)}{\sqrt{\frac{s_x^2}{m} + \frac{s_y^2}{n}}}$

非正态总体下的估计

分布类型	枢轴变量及其分布	CI(α)
指数分布 $\text{Exp}(\lambda)$	$2\lambda \sum x_i \sim \chi_{2n}^2$	$[\chi_{2n}^2(1 - \frac{\alpha}{2}) \leq 2\lambda \sum x_i \leq \chi_{2n}^2(\frac{\alpha}{2})]$
均匀分布 $U(0, \theta)$	$z = \frac{\theta}{X_{(n)}} \xrightarrow{pdf} n z^{-(n+1)} \mathbb{1}_{(1, \infty)}(z)$	$[1 \leq \frac{\theta}{X_{(n)}} \leq \frac{1}{\sqrt[n]{a}}]$

假设检验(这里仅涉及参数检验)

注意一个点：我们的假设是对于参数空间的，而检验是在样本空间上做的

什么是假设检验？假设检验速览

1. 参数空间上的假设命题 $H_0 \rightarrow H_1$

一般地， H_0 是我们人为设定的，也就是我们所感兴趣的假设；从数学上说， H_0 可以表示为命题 $\theta \in \Theta_0 \subset \Theta$ ，对应地， H_1 可以表示为命题 $\theta \in \Theta_1 = \Theta / \Theta_0$ ，也就是取补集。根据 Θ_0 是否是单点集，可以把ta分为简单假设和复合假设。

2. 基于一份样本的检验：

现在，我们通过简单那随机抽样得到了一份样本 X_1, \dots, X_n ，我们可以先假设 H_0 成立，然后从样本中提取一些信息，即计算一个统计量 $T(X, \theta_0), \theta_0 \in \Theta_0$ ，根据边界值以及 T 的分布所决定的：样本空间 \mathcal{S} 上的拒绝域 D ，来决定“根据这一样本，是否要拒绝原假设”。

现在，我们终于可以定义检验函数 $\phi(T)$ 来描述一个假设检验：

$$\phi(T) = \begin{cases} 1 & \iff T \in D \\ r & \iff T \in \partial D : \text{这一条仅限离散型用到} \\ 0 & \iff T \notin D \end{cases}$$

当然，对于用什么统计量是很有说法的。有一种情况我们单独拿出来讨论：当我们基于MLE，我们要用的统计量就变成了似然比 λ 。此时似然比的表达式一般都很复杂，不会有很好的分布性质。但我们可以从中提取一个分布良好的统计量 T 作为原像，并找到一个双射 $g(\cdot)$ ，使得 $\lambda = g(T)$ 。此时 $P(\lambda = c) = P(g(T) = c) = P(T = g^{-1}(c))$ ，从而我们可以把分析对象改为 T ，得到可以求解的 $\phi(T)$ 。

3. 如何评价一个检验

由于样本的随机性，我们不能保证基于样本判定假设正误的绝对可靠性，对此我们用该检验**犯错误**的概率衡量：

	$\phi(T) = 0$	$\phi(T) = 1$
$\theta \in \Theta_0$	✓	I – error
$\theta \in \Theta_1$	II – error	✓

我们对此引入**功效函数(势函数)**：给定总体参数条件下的拒绝概率

$P(\phi = 1|\theta) \stackrel{def}{=} \beta_\phi(\theta)$ ，ta与两类错误的发生概率的关系是：

$$\beta_\phi(\theta) = \mathbb{1}_{\theta \in \Theta_0} P(\text{I – error}) + \mathbb{1}_{\theta \in \Theta_1} (1 - P(\text{II – error}))$$

作为一个优秀的检验，我们希望 $\phi(\cdot)$ 所带来的两类错误的概率都越小越好，但是这很难做到：一般地，降低I – error的方法是缩小 D ，但是这一操作往往会导致II – error的发生概率升高。

面对这一权衡，我们依据Neyman – Pearson原则：在约定I – error发生概率上限(显著性水平)的条件下最小化II – error的发生概率，此时对应最优检验称为UMPT。这么做的动机是：我们认为I – error的成本更高，我们更不希望这一类错误的发生


正态总体假设检验:基于统计量与原假设的"距离"判断、

🔪 对于复合原假设，我们需要额外证明 $\forall \theta_0 \in \Theta_0, \beta_\phi(\theta_0) \leq \alpha$ ，也就是证明功效函数的单调性

检验 & 置信区间

置信区间是基于样本给出的参数真实值的区间估计，不止于判决原假设的正误，置信区间还给出了一定置信水平下，真实参数的取值范围与原假设的差距大小：

下图“X_1”是第一份样本得出的 $(1 - \alpha)$ 置信区间，下图“X_1”是第二份样本得出的 $(1 - \alpha)$ 置信区间， θ 是简单原假设的参数值。可以看出第二份样本“X_2”下得出的 θ 估计显著异于原假设，而“X_1”的差距就没那么显著



检验 & p-值

基于样本和原假设，我们可以算出一个检验统计量 $T(X, \theta_0)$ ，此时可以计算出在原假设成立条件下，抽样到比已有样本更“偏离原假设”的样本的概率：

$$P(|T(X_{new}, \theta_0)| > |T(X, \theta_0)|) \stackrel{def}{=} \text{p-value}$$

如果这个值很小，说明在原假设条件下，抽到已有样本的概率很低，从而说明原假设不太可信，可以拒绝



检验结论总结(书上表格)

表 5.2.1 单个正态总体均值的假设检验

	H_0	H_1	检验统计量及其分布	否定域
σ^2 已知	$\mu = \mu_0$	$\mu \neq \mu_0$	$U = \sqrt{n}(\bar{X} - \mu_0)/\sigma$ $U \mu = \mu_0 \sim N(0, 1)$	$ U > u_{\alpha/2}$
	$\mu \leq \mu_0$	$\mu > \mu_0$		$U > u_{\alpha}$
	$\mu \geq \mu_0$	$\mu < \mu_0$		$U < -u_{\alpha}$
σ^2 未知	$\mu = \mu_0$	$\mu \neq \mu_0$	$T = \sqrt{n}(\bar{X} - \mu_0)/S$ $T \mu = \mu_0 \sim t_{n-1}$	$ T > t_{n-1}(\alpha/2)$
	$\mu \leq \mu_0$	$\mu > \mu_0$		$T > t_{n-1}(\alpha)$
	$\mu \geq \mu_0$	$\mu < \mu_0$		$T < -t_{n-1}(\alpha)$

表 5.2.2 单个正态总体方差的假设检验

	H_0	H_1	检验统计量及其分布	否定域
μ 已知	$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\chi^2_{\mu} = nS_{\mu}^2/\sigma_0^2$ $\chi^2_{\mu} \sigma_0^2 \sim \chi_n^2$	$nS_{\mu}^2/\sigma_0^2 < \chi_n^2(1 - \alpha/2)$ 或 $nS_{\mu}^2/\sigma_0^2 > \chi_n^2(\alpha/2)$
	$\sigma^2 \leq \sigma_0^2$	$\sigma^2 > \sigma_0^2$		$nS_{\mu}^2/\sigma_0^2 > \chi_n^2(\alpha)$
	$\sigma^2 \geq \sigma_0^2$	$\sigma^2 < \sigma_0^2$		$nS_{\mu}^2/\sigma_0^2 < \chi_n^2(1 - \alpha)$
μ 未知	$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$ $\chi^2 \sigma_0^2 \sim \chi_{n-1}^2$	$(n-1)S^2/\sigma_0^2 < \chi_{n-1}^2(1 - \alpha/2)$ 或 $(n-1)S^2/\sigma_0^2 > \chi_{n-1}^2(\alpha/2)$
	$\sigma^2 \leq \sigma_0^2$	$\sigma^2 > \sigma_0^2$		$(n-1)S^2/\sigma_0^2 > \chi_{n-1}^2(\alpha)$
	$\sigma^2 \geq \sigma_0^2$	$\sigma^2 < \sigma_0^2$		$(n-1)S^2/\sigma_0^2 < \chi_{n-1}^2(1 - \alpha)$

表 5.2.3 两个正态总体均值差的假设检验

	H_0	H_1	检验统计量 及其分布	否定域
$\sigma_1^2 = \sigma_2^2$	$\mu_2 - \mu_1 = \mu_0$	$\mu_2 - \mu_1 \neq \mu_0$	$U = \frac{\bar{Y} - \bar{X} - \mu_0}{\sqrt{\sigma_1^2/m + \sigma_2^2/n}}$ $U \mu_0 \sim N(0, 1)$	$ U > u_{\alpha/2}$
已	$\mu_2 - \mu_1 \leq \mu_0$	$\mu_2 - \mu_1 > \mu_0$		$U > u_\alpha$
知	$\mu_2 - \mu_1 \geq \mu_0$	$\mu_2 - \mu_1 < \mu_0$		$U < -u_\alpha$
$\sigma_1^2 \neq \sigma_2^2$	$\mu_2 - \mu_1 = \mu_0$	$\mu_2 - \mu_1 \neq \mu_0$	$T_w = \frac{\bar{Y} - \bar{X} - \mu_0}{S_w} \sqrt{\frac{mn}{m+n}}$ $T_w \mu_0 \sim t_{n+m-2}$ $S_w^2 = \frac{(m-1)S_1^2 + (n-1)S_2^2}{n+m-2}$	$ T_w > t_{n+m-2} \left(\frac{\alpha}{2} \right)$
σ_2^2	$\mu_2 - \mu_1 \leq \mu_0$	$\mu_2 - \mu_1 > \mu_0$		$T_w > t_{n+m-2}(\alpha)$
未知	$\mu_2 - \mu_1 \geq \mu_0$	$\mu_2 - \mu_1 < \mu_0$		$T_w < -t_{n+m-2}(\alpha)$

表 5.2.4 两个正态总体方差比的假设检验

	H_0	H_1	检验统计量及其分布	否定域
μ_1	$\sigma_2^2 = \sigma_1^2$	$\sigma_2^2 \neq \sigma_1^2$	$F_* = S_{2*}^2 / S_{1*}^2$ $F_* \sigma_2^2 = \sigma_1^2 \sim F_{n,m}$ $S_{1*}^2 = \frac{1}{m} \sum_{i=1}^m (X_i - \mu_1)^2$ $S_{2*}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \mu_2)^2$	$F_* < F_{n,m}(1 - \alpha/2)$ 或 $F_* > F_{n,m}(\alpha/2)$
μ_2	$\sigma_2^2 \leq \sigma_1^2$	$\sigma_2^2 > \sigma_1^2$		$F_* > F_{n,m}(\alpha)$
已知	$\sigma_2^2 \geq \sigma_1^2$	$\sigma_2^2 < \sigma_1^2$		$F_* < F_{n,m}(1 - \alpha)$
μ_1	$\sigma_2^2 = \sigma_1^2$	$\sigma_2^2 \neq \sigma_1^2$	$F = S_2^2 / S_1^2$ $F \sigma_2^2 = \sigma_1^2 \sim F_{n-1, m-1}$ $S_1^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2$ $S_2^2 = \frac{1}{n-1} \sum_{j=1}^n (Y_j - \bar{Y})^2$	$F < F_{n-1, m-1}(1 - \alpha/2)$ 或 $F > F_{n-1, m-1}(\alpha/2)$
μ_2	$\sigma_2^2 \leq \sigma_1^2$	$\sigma_2^2 > \sigma_1^2$		$F > F_{n-1, m-1}(\alpha)$
未知	$\sigma_2^2 \geq \sigma_1^2$	$\sigma_2^2 < \sigma_1^2$		$F < F_{n-1, m-1}(1 - \alpha)$

似然比检验: literally

如果我们用似然程度去检验原假设的话，那么就是接下来要记录的似然比检验。如果原假设条件下的“极大似然值”和无约束条件下的“极大似然值”（也就是正常求解MLE的过程所得到的结果）**很接近**，那么我们就倾向于接受原假设；反之则拒绝原假设。

$$L_{\Theta_0}(x) = \sup_{\theta \in \Theta_0} f(x, \theta)$$

$$L_{\Theta}(x) = \sup_{\theta \in \Theta} f(x, \theta)$$

$$\lambda(x) = \frac{L_{\Theta}(x)}{L_{\Theta_0}(x)} \geq 1 \text{ (似然比)}$$

$$\phi(x) = \begin{cases} 1, & \lambda(x) > c \\ r, & \lambda(x) = c \text{ (检验函数)} \\ 0, & \lambda(x) < c \end{cases}$$

由于 $\lambda(x)$ 未必有很好的分布，我们通常从 $\lambda(x)$ 的表达式中提取一个**具有良好分布的充分统计量**： T 使得 $\lambda(x) = g(T)$ ，其中 $g(\cdot)$ 是**单调函数**，从而可以将 $\phi(x)$ 改写为 $\phi(T)$ 的形式，更好得到边界值。

书上有很多例子，自己动手算吧，没啥能记的

这里再记一个关于 $\lambda(x)$ 极限分布的Wilks定理

Theorem

Assume the dimensions of Θ and Θ_0 are k and s respectively. If $k - s = t > 0$ and the density function of the sample satisfies the CR-conditions in Page 109, then for the testing problem $H_0 : \theta \in \Theta_0 \leftrightarrow H_1 : \theta \in \Theta_1$, we have

$$2 \log \lambda(\mathbf{X}) \xrightarrow{d} \chi_t^2$$

under H_0 and as $n \rightarrow \infty$.

Dimension: Suppose the sample are generated from $N(\mu, \sigma^2)$, and we want to test $H_0 : \mu = 0 \leftrightarrow H_1 : \mu \neq 0$. Then the dimension of $\Theta_0 = \{\theta = (0, \sigma^2), \sigma^2 > 0\}$ is 1; the dimension of $\Theta = \{\theta = (\mu, \sigma^2), -\infty < \mu < \infty, \sigma^2 > 0\}$ is 2.

UMPT & UMPUT

直到现在，我们还没有像在点估计那里一样，对假设检验进行优化、比较。现在我们给出评价一个假设检验的具体内容。

由于我们以犯第二类错误的概率评价，我们可以由此定义水平为 α 的UMPT： ϕ

$$\begin{aligned} \forall \theta_0 \in \Theta_0 : \beta_\phi(\theta_0) &\leq \alpha : \phi \in \Phi(\alpha) \\ \forall \theta_1 \in \Theta_1, \phi_1 \in \Phi(\alpha) : \beta_\phi(\theta_1) &\geq \beta_{\phi_1}(\theta_1) \end{aligned}$$

也就是 ϕ 不犯第二类错误的概率在所有水平为 α 的检验中最低

N-P 引理

那么如何得到一个UMPT？只有在一定条件下N – P Lemma才能给出一个基于（原始定义下的）似然比检验的UMPT

书上的证明很有趣，但是有点长，理解欣赏就好

(NP Lemma) Suppose the density function of sample \mathbf{X} is $f(\mathbf{x}, \theta)$ and there are only two possible values for θ . Consider the following testing problem:

$$H_0 : \theta = \theta_0 \leftrightarrow H_1 : \theta = \theta_1, \quad (3)$$

then for any given $0 < \alpha < 1$, we have

Existence & UMPT: There must exist testing function $\varphi(\mathbf{x})$, and fixed numbers $c, r > 0$ satisfies: (i).

$$\varphi(\mathbf{x}) = \begin{cases} 1, & \text{if } f(\mathbf{x}, \theta_1)/f(\mathbf{x}, \theta_0) > c; \\ r, & \text{if } f(\mathbf{x}, \theta_1)/f(\mathbf{x}, \theta_0) = c; \\ 0, & \text{if } f(\mathbf{x}, \theta_1)/f(\mathbf{x}, \theta_0) < c. \end{cases} \quad (4)$$

(ii) $E_{\theta_0}[\varphi(\mathbf{X})] = \alpha$. This $\varphi(\mathbf{X})$ is the UMPT of (3).

基于N-P引理求一般假设问题的UMPT

基于N – P Lemma我们可以逐步推出其他假设形式的UMPT：举一个例子

$\{H_0 : \mu = 0, H_1 : \mu = \mu_1 > 0\}$ 可以通过引理求出UMPT： ϕ
→ $\{H_0 : \mu = 0, H_1 : \mu > 0\}$ 的UMPT是 ϕ , 如果UMPT和 μ 无关
→ $\{H_0 : \mu \leq 0, H_1 : \mu > 0\}$ 的UMPT是 ϕ , 如果 $\beta(x)$ 关于 μ 单增
也就是 ϕ 在 H_0 上具有 α 的检验水平

一般情况下就是：

- $\{H_0 : \mu \in \Theta_0, H_1 : \mu \in \Theta_1\}$ 的UMPT是 ϕ , 如果 $\beta(x)$ 关于 μ 单调
也就是 ϕ 在 H_0 上具有 α 的检验水平
 $\leftarrow \{H_0 : \mu = \partial\Theta_0, H_1 : \mu \in \Theta_1\}$ 的UMPT是 ϕ , 如果UMPT和 μ 无关
 $\leftarrow \{H_0 : \mu = \partial\Theta_0, H_1 : \mu = \mu_1 \in \Theta_1\}$ 可以通过引理求出UMPT : ϕ

这一套流程的必要条件是：

1. 原假设只能有一个边界点，具体说就是参数空间是 \mathbb{R} 子集，且原假设是单边的
 2. $\beta(x)$ 在 H_0 上关于参数单调
 3. $\phi(x)$ 与表达式参数无关
- 而对于指数族 $\mathcal{F} = \{f(x, \theta) = c(\theta) \exp(Q(\theta)T(x))h(x)\}$ ，功效函数的单调性与 $Q(\theta)$ 的单调性有关（详见定理5.4.2/3）

UMPUT

至于UMPUT，无非是进一步限制了考虑的检验函数的范围，从而更有可能求出一个最优的检验。毕竟UMPT不是总能求出来的。

Definition

Suppose φ is a test of testing problem $H_0 : \theta \in \Theta_0 \leftrightarrow H_1 : \theta \in \Theta_1$. If the power function of φ — $\beta_\varphi(\theta)$ satisfies that: for any $\theta_0 \in \Theta_0$, we have $\beta_\varphi(\theta_0) \leq \alpha$, and for any $\theta_1 \in \Theta_1$, we have $\beta_\varphi(\theta_1) \geq \alpha$, then we call φ as an unbiased test with significance level α .

Definition

Denote \mathcal{U}_α as a set contains all the unbiased tests with significance level α for testing problem $H_0 : \theta \in \Theta_0 \leftrightarrow H_1 : \theta \in \Theta_1$. Suppose $\varphi \in \mathcal{U}_\alpha$, and for any $\varphi_1 \in \mathcal{U}_\alpha$, we have

$$\beta_\varphi(\theta) \geq \beta_{\varphi_1}(\theta) \quad \theta \in \Theta_1,$$

then we call φ as the uniformly most powerful unbiased test.

所谓无偏检验满足以下条件的检验函数 $\phi(x)$ ：

$$\forall \theta_0 \in \Theta_0, \theta_1 \in \Theta_1, \beta_\phi(\theta_0) \leq \alpha \leq \beta_\phi(\theta_1)$$

即犯第一类错误的概率不大于**不犯**第二类错误的概率

- If φ is an UMPT, then it must be an UMPUT. Let $\varphi^* \equiv \alpha$, then φ^* is a test with significance level α such that $\beta_{\varphi}(\theta_1) \geq \beta_{\varphi^*}(\theta_1) \equiv \alpha$, therefore

$$\beta_{\varphi}(\theta_1) \geq \alpha \geq \beta_{\varphi}(\theta_0).$$

- The UMPUT of the following testing problems exist.

$$H_0 : \theta = \theta_0 \leftrightarrow H_1 : \theta \neq \theta_0,$$

$$H_0 : \theta_1 \leq \theta \leq \theta_2 \leftrightarrow H_1 : \theta < \theta_1 \text{ or } \theta > \theta_2.$$

此处的 $\phi^* \equiv \alpha$ 指的是，无论样本如何，均有 α 概率随机拒绝原假设(类似于掷骰子)；最后两类检验问题的UMPT不存在

指数族分布专题

[六大常用分布的矩估计和最大似然估计推导过程 常见分布的似然估计量-CSDN 博客](#)

指数族分布	样本联合pdf
$N(\mu, \sigma^2)$	$f(x, \theta) = (\sqrt{2\pi n})^{-n} \exp\left(-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2\right)$
$\text{Exp}(\lambda)$	$f(x, \theta) = \prod (\lambda e^{-\lambda x_i} \mathbb{1}_{(0, \infty)}(x_i))$
$\Gamma(\gamma, \lambda), \gamma$ 已知	$f(x, \theta) = \frac{\lambda^{\gamma n}}{\Gamma(\gamma)^n} \exp(-\lambda \sum x_i) \prod x_i^{\gamma-1} \mathbb{1}_{(0, \infty)}(x_i)$
$b(1, p)$	$f(x, \theta) = p^{\sum x_i} (1-p)^{n-\sum x_i}$
$\text{Poisson}(\lambda)$	$f(x, \theta) = \frac{e^{-n\lambda}}{\prod (x_i)!} \lambda^{\sum x_i}$

指数族分布	自然参数形式pdf	自然参数空间
$N(\mu, \sigma^2)$	$(\sqrt{2\pi n})^{-n} \exp\left(-\frac{n\mu^2}{2\sigma^2}\right) \exp\left(\frac{\mu}{\sigma^2} \sum x_i - \frac{1}{2\sigma^2} \sum x_i^2\right)$	$\mathbb{R} \times \mathbb{R}^-$
$\text{Exp}(\lambda)$	$\lambda^n \exp(-\lambda \sum x_i) \prod \mathbb{1}_{(0, \infty)}(x_i)$	\mathbb{R}^-
$\Gamma(\gamma, \lambda), \gamma$ 已知	$\frac{\lambda^{\gamma n}}{\Gamma(\gamma)^n} \exp(-\lambda \sum x_i) \prod x_i^{\gamma-1} \mathbb{1}_{(0, \infty)}(x_i)$	\mathbb{R}^-
$b(1, p)$	$(1-p)^n \exp\left(\ln\left(\frac{p}{1-p}\right) \sum x_i\right)$	\mathbb{R}

指数族分布	自然参数形式pdf	自然参数空间
Poisson(λ)	$e^{-n\lambda} \exp(\ln(\lambda) \sum x_i) \frac{1}{\prod (x_i)!}$	\mathbb{R}

指数族分布	$N(\mu, \sigma^2)$	Exp(λ) 均值 $\frac{1}{\lambda}$	$b(1, p)$	Poisson(λ)
c. s. s.	$(\sum x_i, \sum x_i^2)$	$\sum x_i$	$\sum x_i$	$\sum x_i$
MLE	$(\bar{X}, \frac{\sum (x_i - \bar{x})^2}{n} = \frac{(n-1)S^2}{n})$	\bar{X}	\bar{X}	\bar{X}
UMVUE	$(\bar{X}, S^2 = \frac{\sum x_i^2}{n-1})$	\bar{X}	\bar{X}	\bar{X}

!均匀分布专题

😞 少有的不属于指数族的常见分布

对于均匀分布，我们经常通过线性变换把区间参数消去

$$X \sim U(a, b) \rightarrow \frac{X-a}{b-a} \sim U(0, 1)$$

$$X \sim U(0, \theta) \rightarrow \frac{X}{\theta} \sim U(0, 1)$$

$$X \sim U(-\frac{\theta}{2}, \frac{\theta}{2}) \rightarrow \frac{X}{\theta} \sim U(-\frac{1}{2}, \frac{1}{2})$$

$U(0, 1)$ 的次序统计量

对于 $U(0, 1)$ ，我们还有进一步的结论：围绕Beta分布

[数理统计4：均匀分布的参数估计，次序统计量的分布，Beta分布 - 江景景景页 - 博客园](#)

[如何通俗理解 beta 分布？ - 知乎](#)

次序统计量：

$$f_{(1)}(x) = n(1-x)^{n-1} = \frac{\Gamma(n+1)}{\Gamma(1)\Gamma(n)} x^{1-1}(1-x)^{n-1}$$

$$\sim Be(1, n = 1 + (n - 1))$$

$$f_{(n)}(x) = n(x)^{n-1} = \frac{\Gamma(n+1)}{\Gamma(1)\Gamma(n)} (x)^{n-1}(1-x)^{1-1}$$

$$\sim Be(n = 1 + (n - 1), 1)$$

$$f_{(m)}(x) = \frac{n!}{(m-1)!(n-m)!} (1-x)^{n-m} x^{m-1} = \frac{\Gamma(n+1)}{\Gamma(m)\Gamma(n-m+1)} (1-x)^{n-m+1-1} x^{m-1}$$

$$\sim Be(m = 1 + (m - 1), 1 + (n - m))$$

极差：

$$f_{(n)} - f_{(1)} \stackrel{pdf}{=} n(n-1)r^{n-2}(1-r) = \frac{\Gamma(n+1)}{\Gamma(n-1)\Gamma(2)} r^{n-1-1}(1-r)^{2-1} \sim Be(n-1, 2)$$

极差与 $f_{(n-1)}$ 同分布，等效于容量为 $(n-1)$ 的样本的最大值的分布(to be justified, just an inspiration)

对于 $Be(a, b)$:

$$E[X] = \frac{a}{a+b} = \mu$$
$$Var[X] = \frac{ab}{(a+b)^2(a+b+1)} = \frac{\mu(1-\mu)}{\alpha+\beta+1} = \frac{\mu(1-\mu)}{\varphi+1}$$

$U(0, \theta)$ 的估计

s.s. & c.s.s. $X_{(n)}$

其中充分统计量的证明可以直接用因式分解(次序统计量这是普适的充分统计量)

而完全统计量的证明则需要按照定义引入零无偏估计量

$\phi(X_{(n)}) : E_{\theta}(\phi(X_{(n)})) = 0$ 然后证明 $\phi = 0$, *a. s.* (书上例题2.8.2)

MLE $X_{(n)}$

这个是因为样本的条件联合分布函数 $f = \theta^{-n} \mathbf{1}_{X_{(n)} \leq \theta}(x)$, 关于 θ 递增, 所以应该是分母尽可能的小; 同时可以发现 $\theta < X_{(n)} \rightarrow f(x) = 0$, 所以 θ 的下界就是 $X_{(n)}$

UE & UMVUE $\frac{1+n}{n} X_{(n)}$

这个就算一下 X_n 的期望, 然后对其代数变换一下就好了; 至于 UMVUE, 是从上面 c. s. s. 引出来的(用 L-S 定理)

均匀分布 $U(0, \theta)$	结果
s. s.	$X_{(n)}$
c. s. s.	$X_{(n)}$
MLE	$X_{(n)}$
UMVUE	$\frac{1+n}{n} X_{(n)}$