

随机过程

Drown Genius Drown Genius Drown Genius

时齐马氏链闲聊

★递推思想:小步向前/向后

利用全概率公式/条件期望嵌套,考虑马氏链的一步转移,从而利用时齐马氏链的良好性质得到想要研究的事件的概率/期望值的递推表达式。

ta的具体形式取决于时期的假设:离散时间——差分方程;连续时间——微分方程

★时间上的分划

离散时间离散状态马氏链

默认:此处概率向量都是行向量,向量函数都是列向量,运算顺序从左向右;我们这里默认时齐性成立

马尔可夫性

设初始概率向量是 μ ,转移概率矩阵是 \mathbf{P} ,马尔可夫性指的是:

$$P(X_n | X_{n-1}, \dots, X_0) = P(X_n | X_{n-1}) = P(X_1 | X_0)$$

- 基于马氏性可以推导出联合概率:

$$P(X_0 = i_0, \dots, X_n = i_n) = \mu_{i_0} P_{(i_0, i_1)} \cdots P_{(i_{n-1}, i_n)}$$

- 基于马氏性可以推导出两步转移概率:

$$\begin{aligned} P(X_{n+2} = j | X_n = k) &= \sum_i P(X_{n+2} = j | X_{n+1} = i, X_n = k) P(X_{n+1} = i | X_n = k) \\ &= \sum_i P(X_1 = j | X_0 = i) P(X_1 = i | X_0 = k) \\ &= P_{(j)} P_{(k,)} \\ &= P_{(k, j)}^2 \end{aligned}$$

- 进而我们可以归纳出m步转移概率: $P(X_{n+m} = j | X_n = k) = P_{(k, j)}^m$
- 从向量角度考虑,给定 μ ,每一步转移实质上就是在对 μ 右乘以概率矩阵 \mathbf{P} ,而转移m步即是一步转移的m次复合 $\mathbf{P} \cdot \mathbf{P} \cdot \mathbf{P} \cdots \mathbf{P} = \mathbf{P}^m$

- 函数值的期望，假设 f 是一个列向量， $f(X)$ 是一个数

$$E(f(X_n)|X_0 = i_0) = \sum_j P_{(i_0,j)}^n f(j) = (P^n f)_{(i),n \times 1}$$

$$E(f(X_n)) = E(E(f(X_n)|X_0 = i_0)) = \sum_i \mu_i P^n f = (\mu P^n f)_{1 \times 1}$$

离散时间下的C-K方程(本质上是全概率公式)

基于上述关于 m 步转移概率的推导和马尔可夫性，我们很容易可以得到C-K方程：

$$P_{i,j}^{m+n} = \sum_k P_{i,k}^m P_{k,j}^n \quad \text{其矩阵表述就是 } \mathbf{P}^{m+n} = \mathbf{P}^m \mathbf{P}^n$$

$$\begin{aligned} P(X_{m+n+k} = i | X_k = j) &= \sum_q P(X_{m+n+k} = i | X_k = j, X_{n+k} = q) P(X_{n+k} = q | X_k = j) \\ &= \sum_q P(X_m = i | X_0 = q) P(X_n = q | X_0 = j) \end{aligned}$$

概率矩阵的一些性质(digression)

如果 \mathbf{P} 有一重特征值1: 记 $\mathbf{P} = \mathbf{Q}^{-1} \mathbf{A} \mathbf{Q}$ ，其中 \mathbf{A} 是对角阵

- 特征值1对应的特征向量是 $(1, 1, \dots, 1)'$
因为 \mathbf{P} 的每一行的和是1， $\mathbf{I} - \mathbf{P}$ 的每一行的和是0，从而
 $(\mathbf{I} - \mathbf{P})(1, 1, \dots, 1)' = \mathbf{0}$
- \mathbf{Q}^{-1} 中向量 $(1, 1, \dots, 1)'$ 对应的那个行向量 $\boldsymbol{\pi}$ 的各元素和为1
利用伴随矩阵可以知道，这一行各个元素是向量 $(1, 1, \dots, 1)'$ 各个元素对应的代数余子式除以行列式的值，依据行列式按列分解的算法可知这个行向量的各元素和为1 (分子求和就是行列式的值)
进一步假设 \mathbf{P} 的其他特征值的绝对值小于1，那么
 $\lim_{n \rightarrow \infty} \mathbf{P}^n = \lim_{n \rightarrow \infty} \mathbf{Q}^{-1} \mathbf{A}^n \mathbf{Q}$ 此时 \mathbf{A} 只剩下对角线上的一个非零值:1，
从而 $\lim_{n \rightarrow \infty} \mathbf{A}^n \mathbf{Q}$ 只有一行全是1，其余皆0， $\lim_{n \rightarrow \infty} \mathbf{Q}^{-1} \mathbf{A}^n \mathbf{Q}$ 每一行都是 \mathbf{Q}^{-1} 中向量 $(1, 1, \dots, 1)'$ 对应的那个行向量 $\boldsymbol{\pi}$ 此时对任一初始概率 $\boldsymbol{\mu}$ ，
 $\lim_{n \rightarrow \infty} \boldsymbol{\mu} \mathbf{P}^n = \boldsymbol{\pi}$ 。这就是一个马尔可夫过程稳定的极限分布

状态分析

从返回情况分类

在这里，我们是从时间维度延展的，我们一般假设起点是确定的，也就是从一个概率分布类似于 $(0, \dots, 1, 0)$ 的随机变量出发，去分析这个随机变量在若干步转移过程中体现的特征，对此我们浓缩为两个问题：

- 到底会不会返回初始状态？如果返回，那么返回的期望次数是多少？
- 返回一次所用的阶段数全体构成的集合有什么特征？

3. 不同状态之间的返回情况有什么关系吗？

对于第一个问题，我们先定义了一系列r. v.：

def：

$\tau_j = \inf_{n \geq 1} \{X_n = j\}$ 首次返回j的时间

$f_{ij} = P(\tau_j < \infty | X_0 = i)$ 从i出发，终究能返回的概率

1. 至此，我们可以用概率的形式描述上面两个问题并对状态进行分类：

1. $f_{ii} < 1$ or $f_{ii} = 1$

前者定义为“**非常返/暂留**” 后者定义为“**常返**”

2. $E(\tau_j | X_0 = j) < \infty$ or $E(\tau_j | X_0 = j) = \infty$

前者定义为“**正常返**” 后者定义为“**零常返**”

2. 而对于第二个问题，我们可以定义集合 $D = \{d : P_{ii}^d > 0\}$ 并进一步定义 $d = \gcd(D)$ 作为这个**状态的周期**

3. 而当我们考虑多个状态之间的关系的时候，我们首先看它们之间是否是**互通的**，即存在互通路径： $\exists(m, n) : P_{ij}^m P_{ji}^n > 0$

互通关系可以视为一个等价关系，因为ta满足“自反性、传递性、对称性”，从而存在互通关系的状态全体构成了一个互通(等价)类

可以证明互通类内部各个状态的周期、常返性是一致的

如果所有状态都是互通的，我们称这个过程是**不可约的**

常返的判定(1)

一方面我们可以将 f_{ii} 分划：

$$f_{ii} = P(\tau_i < \infty | X_0 = i) = \sum_{t=1}^{\infty} P(\tau_i = t | X_0 = i) = \sum_{t=1}^{\infty} f_{ii}^{(t)}$$

另一方面，我们考虑r. v. N_i 表示从i出发，返回i的总次数，它的期望是：

$$E(N_i | X_0 = i) = E\left(\sum_{t=0}^{\infty} \mathbb{1}_{X_t=i}(t)\right) = \sum_{t=0}^{\infty} P_{ii}^t = \sum_{t=1}^{\infty} P_{ii}^t + 1$$

除此，我们还可以把 P_{ii}^t 进行分划： $P_{ii}^t = \sum_{k=0}^t f_i^{(k)} P_{ii}^{t-k}$ 带入 $E(N_i)$ 得：

$$\begin{aligned}
E(N_i) &= E\left(\sum_{t=0}^{\infty} \mathbb{1}_{X_t=i}(t)\right) = 1 + \sum_{t=1}^{\infty} P_{ii}^t \\
&= 1 + \sum_{t=1}^{\infty} \sum_{k=1}^t f_i^{(k)} P_{ii}^{t-k} = 1 + \sum_{k=1}^{\infty} \sum_{t=k}^{\infty} f_i^{(k)} P_{ii}^{t-k} \\
&= 1 + \sum_{k=1}^{\infty} f_i^{(k)} \cdot \sum_{l=0}^{\infty} P_{ii}^l \\
&= 1 + f_{ii} E(N_i) \\
&\rightarrow E(N_i) = \frac{1}{1 - f_{ii}} = \sum_{i=0}^{\infty} i f_{ii}^i (1 - f_{ii})
\end{aligned}$$

最后一行给出了另外一种视角：视 f_{ii} 为常数，则一个从 i 出发，返回次数为 n 的过程可以分划为：先返回 n 次，最后再也不返回，从而得到最后一个式子

常返的判定(2)

这时我们利用全概率公式看一看经过一步转移后 f_{ii} 变成了什么样：

$$\begin{aligned}
f_{ii} &= P(\tau_j < \infty | X_0 = i) = \sum_j P(\tau_i < \infty | X_1 = j, X_0 = i) P(X_1 = j | X_0 = i) \\
&= \sum_j P(\tau_i < \infty | X_1 = j) P_{ij} \\
&= \sum_j P(\tau_i < \infty | X_0 = j) P_{ij}
\end{aligned}$$

考虑向量 $\mathbf{f} = (f_{1i} \cdots f_{ii} \cdots)'$ 则可以得到一个线性方程组： $\mathbf{f} = \mathbf{P}\mathbf{f}$ 从而可解 f_{ii}

如果状态空间是可数无穷的，那么依靠以下充要条件可以判别：

如果上述方程组的**任意非负有界解是常数**，那么状态 i 常返

如果上述方程组存在非负、非常数、有界解，那么状态 i 非常返

正常返的判定

这里给出一个浅显、直觉的描述，因为严格的数学证明很复杂：

我们的目标是判断从 i 出发，**首次返回的期望**时间 $E(\tau_j | X_0 = j)$ 的大小。加入我们把眼光放长远一些，考虑从 i 出发， **k 次返回的期望**时间的大小。依据时齐马尔可夫性，这个值可以视为 k 个首次返回的独立和，从而ta的大小就是

$kE(\tau_j | X_0 = j)$ ，这意味着 $kE(\tau_j | X_0 = j)$ 时间内访问了 k 次状态 i ，即有 $\frac{1}{E(\tau_j | X_0 = j)}$ 比例的时间是在状态 j 的

假如若干步转移后，存在一个极限分布 π ，那么：

$$k = E(N_j | X_0 = j) = E(\sum_{t=0}^{\infty} \mathbb{1}_{X_t=j}(t)) = \lim_{n \rightarrow \infty} \sum_{t=0}^n P_{jj}^t \sim \lim_{n \rightarrow \infty} n \bar{\pi}_j$$

这个式子表示在 n 步转移中，有 $\bar{\pi}_j$ 比例的时间是在状态 j 的

令 $n = kE(\tau_j | X_0 = j)$ ，可以得到： $E(\tau_j | X_0 = j) = \frac{1}{\bar{\pi}_j}$ （时空不同视角）

判别定理：对于不可约马氏链，以下条件等价

1. 这个马氏链是正常返的
2. 存在唯一不变分布 $\bar{\pi} : \bar{\pi} = \bar{\pi}P$

如果这个马氏链还是非周期的，那么还与以下条件等价：

3. $\lim_{n \rightarrow \infty} P_{ij}^n = \bar{\pi}_j$

即无论起点的随机变量服从什么分布，经过若干步转移后，总会收敛到一个稳定分布，这一点我们称之为**遍历性**（不可约+非周期+正常返）

实例：分支过程

做题技巧：人为设定吸收态

连续时间离散状态马氏链

独立增量性是马尔可夫性的充分条件

Levy过程(独立平稳增量过程)

Poisson过程(一类特殊的Levy过程)

泊松过程 $\{N(t), t \geq 0\}$ 的状态空间是 \mathbf{N} ， $N(t)$ 满足：

$$P(N_{t+\Delta t} = i | N_t = i) = P(N_{\Delta t} = 0) = 1 - \lambda \Delta t + o(\Delta t)$$

$$P(N_{t+\Delta t} = i + 1 | N_t = i) = P(N_{\Delta t} = 1) = \lambda \Delta t + o(\Delta t)$$

$$P(N_{t+\Delta t} \geq 2 | N_t = i) = P(N_{\Delta t} \geq 2) = o(\Delta t)$$

泊松过程可以用以下r. v. 刻画：我们的故事背景是顾客到来问题

def:

$N(t)$ 过程 $[0, t]$ 中到来的顾客数

$\tau_i = \inf_{t \geq 0} \{X(t) \neq i\} - \inf_{t \geq 0} \{X(t) \neq i-1\}$ 顾客到达时间的间隔

(由于独立增量性, τ_i 与 i 的选取无关, 均与 $\inf_{t \geq 0} \{X(t) \neq 0\}$ 独立同分布)

$$W_n = \sum_{i=1}^n \tau_i \quad n \text{ 个顾客到达所需时间}$$

连续时间马氏链(假设状态空间可数)

我们先定义 t 时刻的转移矩阵 $\mathbf{P}(t) = (p_{ij}(t))$, 满足 $\sum_j p_{ij}(t) = 1$; $\mathbf{P}(t)$ 描述了 $[0, t]$ 时间段对应过程的变化信息

假设 $\lim_{t \rightarrow 0} \mathbf{P}(t) = \mathbf{I}$ 极短时间的过程内不会出现状态转移

连续时间下的C-K方程(本质上是全概率公式)

类似于离散时间下, 我们经过同样的推导过程可以得出连续时间下的C-K方程: $P_{i,j}(s+t) = \sum_k P_{i,k}(s)P_{k,j}(t)$, 对于一个时齐马氏链, 当我们分析经过时长 t 的转移后的分布时, **我们总能将这个过程的利用C-K方程(本质上是全概率公式)分割为若干个独立的子过程, 子过程的时长任意。** 这一思想是时齐马氏链的精髓。

换个角度想, 对于连续时间时齐马氏链, C-K方程相当于是 在 $[0, t]$ 时间段任意做分划 $\{[t_n, t_{n+1}]\}$ 而每个时段的过程由于时齐性等价于过程 $[0, t_n - t_{n+1}]$, 这极大方便了我们的分析和计算

转移速率矩阵

由于时间轴变为连续, 我们对 $\mathbf{P}(t)$ 在每个时刻的变化信息很感兴趣, 由此我们对转移矩阵 $\mathbf{P}(t)$ 求导, 令 $t = 0$ 可以得到转移速率矩阵 $\mathbf{Q} = (q_{ij})$

对于转移速率矩阵 \mathbf{Q} , 我们可以发现:

$$\begin{aligned} q_{ii} &= \lim_{t \rightarrow 0} \frac{p_{ii}(t) - 1}{t} \leq 0 \\ q_{ij} &= \lim_{t \rightarrow 0} \frac{p_{ij}(t)}{t} \geq 0 \\ \sum_j q_{ij} &= \lim_{t \rightarrow 0} \frac{\sum_j p_{ij}(t) - 1}{t} = 0 \end{aligned}$$

最后一行的结果也可以这么理解 $\sum_j q_{ij} = \sum_j \frac{\partial p_{ij}(t)}{\partial t} = \frac{\partial 1}{\partial t} = 0$
处于方便, 我们定义 $q_i = \sum_{j \neq i} q_{ij} = -q_{ii} \geq 0$ 为离开速率

我们还可以计算出 $P(X \text{从状态} i \text{转移到了状态} j) = \lim_{t \rightarrow 0} \frac{\frac{p_{ij}(t)}{t}}{\sum_{k \neq i} \frac{p_{ik}(t)}{t}} = \frac{q_{ij}}{q_i}$

柯尔莫哥洛夫向前/向后方程

这两个方程都是用来求 $\mathbf{P}(t)$ 的，核心思想是把C-K方程在起点/终点**关于时间微分**，根据在起点还是在终点微分，分别得到向后/向前方程：

首先根据 \mathbf{Q} 给出 $\mathbf{P}(\Delta t)$ 的表达式：

$$\begin{aligned} p_{ii}(\Delta t) &= 1 + q_{ii}\Delta t + o(\Delta t) \\ p_{ij}(\Delta t) &= q_{ij}\Delta t + o(\Delta t) \\ \mathbf{P}(\Delta t) &= \mathbf{I} + \mathbf{Q} \cdot \Delta t \end{aligned}$$

向后方程

$$\begin{aligned} p_{ij}(t + \Delta t) &= \sum_k p_{ik}(\Delta t) p_{kj}(t) \\ &= p_{ij}(t) + \sum_k q_{ik}\Delta t \cdot p_{kj}(t) + o(\Delta t) \end{aligned}$$

$LHS = p_{ij}(t) + \dot{p}_{ij}(t)\Delta t + o(\Delta t)$ 经泰勒展开有：

$$\dot{p}_{ij}(t) = \sum_k q_{ik} \cdot p_{kj}(t) = (\mathbf{Q}\mathbf{P}(t))_{ij}$$

向前方程

$$\begin{aligned} p_{ij}(t + \Delta t) &= \sum_k p_{ik}(t) p_{kj}(\Delta t) \\ &= p_{ij}(t) + \sum_k p_{ik}(t) \cdot q_{kj}\Delta t + o(\Delta t) \end{aligned}$$

$LHS = p_{ij}(t) + \dot{p}_{ij}(t)\Delta t + o(\Delta t)$ 经泰勒展开有：

$$\dot{p}_{ij}(t) = \sum_k p_{ik}(t) \cdot q_{kj} = (\mathbf{P}(t)\mathbf{Q})_{ij}$$

* 向前方程成立有一定必要条件

无穷小生成元，求解 $\mathbf{P}(t)$

我们依据向后方程可以得出矩阵微分方程：

$$\begin{aligned} \dot{\mathbf{P}}(t) &= \mathbf{Q}\mathbf{P}(t) \\ \mathbf{P}(0) &= \mathbf{I} \end{aligned}$$

这个微分方程的解很简单： $\mathbf{P}(t) = \exp(\mathbf{Q}t)$ ，ta给出了 $\mathbf{P}(t)$ 的通解，同时显示出转移速率矩阵 \mathbf{Q} 和转移矩阵 $\mathbf{P}(t)$ 之间的关系： \mathbf{Q} 生成了 $\mathbf{P}(t)$ ，从而我们称 \mathbf{Q} 为**无穷小生成元**，ta是连续时间马氏链的核心特征（相比之下，离散时间马氏链以转移矩阵 \mathbf{P} 为核心特征）

离散与连续转化

我们注意到 $\mathbf{P}(t) = \lim_{n \rightarrow \infty} (\mathbf{I} + \mathbf{Q} \frac{t}{n})^n = \exp(\mathbf{Q}t)$ ，可以看出，当我们将过程 $[0, t]$ 分划为无穷多个独立同分布的无穷小增量，从而得到了上式。

状态分析

停留时间&转移速率

首先定义r. v. : 首次离开时间 $\tau_i = \inf_{t \geq 0} \{X(t) \neq i, X(0) = i\}$ ，这是一个取值在 $[0, +\infty]$ 的随机变量，我们现在聚焦于一条链，一个特定的过程。

- $\tau_i \sim \text{Exp}(q_i)$

利用C-K方程可以得到：

$$\begin{aligned} P(\tau_i \geq t | X(0) = i) &= P\{[0, t] \text{过程增量为} 0 | X(0) = i\} \\ &= P\{[0, t] \text{过程的任意分划得到的任一子过程增量为} 0 | X(0) = i\} \\ &\quad (\text{考虑标准} n \text{等分} [0, t], \text{令} n \rightarrow \infty) \\ &= \prod_{n=0}^{\infty} q_{ii} \\ &= \lim_{n \rightarrow \infty} (1 - q_i \frac{t}{n} + o(\frac{t}{n}))^n \\ &= e^{-q_i t} \\ &\sim \text{Exp}(q_i) \end{aligned}$$

- τ_i 与 X_{τ_i} 相互独立

通过写联合分布可以看出：

$$\begin{aligned} P(\tau_i \leq t, X_{\tau_i} = j | X(0) = i) &= \sum_{k=0}^n P\{[0, t] n \text{等分划的前} k \text{段为} 0, (k+1) \text{段} | X(0) = i\} \\ &= \sum_{k=0}^n (1 - q_i \frac{t}{n} + o(\frac{t}{n}))^k (q_{ij} \frac{t}{n} + o(\frac{t}{n})) \\ &= q_{ij} \frac{t}{n} \frac{1 - (1 - q_i \frac{t}{n} + o(\frac{t}{n}))^n}{q_i \frac{t}{n} + o(\frac{t}{n})} + o(\frac{t}{n}) \\ &\rightarrow \frac{q_{ij}}{q_i} (1 - e^{-q_i t}), n \rightarrow \infty \\ &= P(X_{\tau_i} = j | X(0) = i) P(\tau_i \leq t | X(0) = i) \end{aligned}$$

对于速率为 λ 的**泊松过程**，基于此可以写出：

$$\begin{aligned} & P(N_{\tau_1} = n | N_0 = 0) \\ &= \int_0^\infty P(N_{\tau_0} = n | t - o(t) \leq \tau_1 \leq t, N(0) = i) P(t - dt \leq \tau_1 \leq t | N_0 = 0) \\ &= \int_0^\infty P(N_{\tau_0} = n | N(0) = i) P(t - dt \leq \tau_1 \leq t | N_0 = 0) \\ &= \int_0^\infty P(N_{\tau_0} = n | X(0) = i) d\tau_1(t) \quad (\tau_1(t) \sim \text{Exp}(\lambda)) \\ &= \int_0^\infty \frac{e^{-\lambda t}}{n!} (\lambda t)^n (\lambda e^{-\lambda t}) dt \\ &= E_{\tau_1} \left(\frac{e^{-\lambda t}}{n!} (\lambda t)^n \right) \end{aligned}$$

不变分布的求法

依据不变分布 π 定义可以得到恒等式： $\pi = \pi \mathbf{P}(t), \forall t \geq 0$

此时等式两边对 t 求导可以得到： $0 = \pi \mathbf{P}(t) \mathbf{Q}, \forall t \geq 0$ （此处用向前方程）

由于不变分布，上式等价于： $0 = \pi \mathbf{Q}$ 这就是不变分布的充要条件

离散状态鞅过程

鞅的定义

一个随机过程 $\mathbf{X} = (\mathbf{X}_1 \dots \mathbf{X}_n \dots)$ 满足： $E(X_{n+1} | X_n) = X_n$ 则称之为鞅过程

鞅差变换/离散版“随机积分”

由于现在还停留在离散时间，所以我们的“积分”只能停留在离散和阶段：给定一个可料的随机过程 $H_n: H_n$ 关于 \mathcal{F}_{n-1} 可测；给定一个鞅 X_n 则可以定义 H_n 关于 X_n 的随机积分 Z_n ：

$$Z_0 = 0, Z_n = \sum_{i=1}^n H_i (X_{i-1} - X_i)$$

连续时间下的随机积分请看后续章节……

停时/抽样时点

随着时间的流逝，我们分析的随机过程会打出一条散点图。如果我们对随机变量的某些状态(如取值)感兴趣，我们便可以记录ta到达这些状态的时间点，

这就是我们所谓的“停时”。同时需要注意的是，停时的记录依赖于 \mathcal{F}_n 之前的信息，所以停时对应的事件是属于 \mathcal{F}_n 的。

举例子：假如股市价格随时间变化的过程是一个随机过程，那我们可以监测股价到达一定下限时买入股票；在到达一定上限时卖出股票，买入、卖出的时间点即是“停时”。

可选停时定理

我们既然对于停时处的状态感兴趣，那么停时处的期望 $E(X_\tau)$ 自然是我们关注的。

为了保证时间上的有界性，我们转而分析r. v. $X_{\tau \wedge n}$ 进而可以得到一个随机过程($X_{\tau \wedge n} = X_{\min\{\tau, n\}}$)

可以证明这个随机过程是一个鞅过程：

$$\begin{aligned} E(X_{\tau \wedge n+1} | \mathcal{F}_n) &= \sum_{k=0}^n X_k 1_{\tau=k} + E\left(\sum_{k=n+1}^{\infty} X_{n+1} 1_{\tau=k} | \mathcal{F}_n\right) \\ &= \sum_{k=0}^n X_k 1_{\tau=k} + E(X_{n+1} 1_{\tau \geq n+1} | \mathcal{F}_n) \\ &= X_\tau 1_{\tau \leq n} + E(X_{n+1} (1 - 1_{\tau \leq n}) | \mathcal{F}_n) \\ &= X_\tau 1_{\tau \leq n} + X_{n+1} (1 - 1_{\tau \leq n}) \\ &= X_{\tau \wedge n+1} \end{aligned}$$

基于此可以给出完整的**可选停时定理**：

对于有界停时 τ 及鞅过程 $\{X_n\}$ 如果满足

1. $E(|X_\tau|) < \infty$
2. $\lim_{n \rightarrow \infty} E(X_n 1_{\tau > n}) = 0 \rightarrow \lim_{n \rightarrow \infty} E(X_\tau 1_{\tau > n}) = 0$ 因为停时对应的事件是全体事件的子集

那么就有 $E(X_\tau) = E(X_0)$

$$E(X_\tau) = E(X_\tau 1_{\tau > n}) + E(X_\tau 1_{\tau \leq n}) = E(X_\tau 1_{\tau > n}) + E(X_{\tau \wedge n}) - E(X_n 1_{\tau > n})$$

由于 $(X_{\tau \wedge n})$ 是一个有界鞅过程： $E(X_{\tau \wedge n}) = E(X_0)$

等式两侧令 $n \rightarrow \infty$ ：

$$E(X_\tau) = \lim_{t \rightarrow \infty} E(X_\tau 1_{\tau > n}) + E(X_0) - \lim_{t \rightarrow \infty} E(X_n 1_{\tau > n})$$

$$E(X_\tau) = E(X_0)$$

Doob-Meyer 分解

对于一个下鞅 X_n , 我们可以**构造一个可料增过程**

$A_n : E(\Delta A_n | \mathcal{F}_{n-1}) = E(\Delta X_n | \mathcal{F}_{n-1}) > 0$ 。此时可以证明 $M_n = X_n - A_n$ 是一个鞅, 从而我们把**一个下鞅分解成了一个鞅和一个可料增过程**

$$\begin{aligned} E(M_{n+1} | \mathcal{F}_n) &= E(M_n + (X_{n+1} - X_n) - (A_{n+1} - A_n) | \mathcal{F}_n) \\ &= M_n + E(\Delta X_{n+1} | \mathcal{F}_n) - E(\Delta A_{n+1} | \mathcal{F}_n) \\ &= M_n \end{aligned}$$

一般地, 我们可以直接令 A_n 满足 $\Delta A_n = E(\Delta X_n | \mathcal{F}_{n-1}) > 0$ 来构造

一致平方可积鞅, 平方变差过程

如果一个鞅 X_n 满足: $E(X_n^2) < \infty, \forall n$, 则称为一致平方可积鞅 (例子: 平均随机游动)

此时对下鞅 $\{X_n^2\}$ 进行D-M分解得到一个可料增过程:

$$A_n : E(\Delta A_n | \mathcal{F}_{n-1}) = E(\Delta(X_n^2) | \mathcal{F}_{n-1})$$

可以证明: 假设 $A_0 = 0$

$$\begin{aligned} E(A_n | \mathcal{F}_{n-1}) &= \sum_{i=1}^n E(\Delta(X_i^2) | \mathcal{F}_{i-1}) \\ &= \sum_{i=1}^n E(X_i^2 - 2X_{i-1}X_i + X_{i-1}^2 | \mathcal{F}_{i-1}) \\ &= \sum_{i=1}^n E(X_i^2 - 2X_{i-1}X_i + X_{i-1}^2 | \mathcal{F}_{i-1}) \\ &= \sum_{i=1}^n E([\Delta(X_i)]^2 | \mathcal{F}_{i-1}) \\ &\rightarrow A_n = \sum_{i=1}^n [\Delta(X_i)]^2 \text{ 满足条件} \end{aligned}$$

此时 $A_n = \sum_{i=1}^n [\Delta(X_i)]^2$ 我们称为平方变差过程

鞅的举例

随机游动

$$X_n = X_0 + \sum_{j=1}^n \xi_j \quad \xi_j \stackrel{i.i.d}{\sim} 0-1 \text{等可能分布}$$

$$M_n = X_n^2 - n$$

$$\begin{aligned} E(M_{n+1} | \mathcal{F}_n) &= E\left((X_0 + \sum_{j=1}^{n+1} \xi_j)^2 - (n+1) | \mathcal{F}_n\right) \\ &= E\left(M_n + 2\xi_{n+1}(X_0 + \sum_{j=1}^n \xi_j) + \xi_{n+1}^2 - 1 | \mathcal{F}_n\right) \\ &= M_n \end{aligned}$$

$$\begin{aligned} X_n^2 &= (X_n^2 - n) + n, \quad X_n^2 - n = 2 \sum_{i=1}^n X_{i-1}(X_i - X_{i-1}) \\ X_n^2 - n &= \sum_{i=1}^n (X_i^2 - X_{i-1}^2 - 1) = \sum_{i=1}^n [(X_i - X_{i-1})^2 - 2X_i^2 + 2X_i X_{i-1} - 1] \\ &= \sum_{i=1}^n 2X_{i-1}(X_i - X_{i-1}), (X_i - X_{i-1})^2 - 1 \equiv 0 \end{aligned}$$

$$M_n = X_n^3 - f(n), f(n) = 3 \sum_{i=0}^{n-1} X_i$$

$$\begin{aligned} E(M_{n+1} | \mathcal{F}_n) &= E\left(\left(X_0 + \sum_{j=1}^{n+1} \xi_j\right)^3 - f(n+1) | \mathcal{F}_n\right) \\ &= E((X_n + \xi_{n+1})^3 - f(n+1) | \mathcal{F}_n) \\ &= E(M_n + f(n) + 3X_n^2 \xi_{n+1} + 3X_n \xi_{n+1}^2 + \xi_{n+1}^3 - f(n+1) | \mathcal{F}_n) \\ &= M_n + f(n) - f(n+1) + 3X_n \\ &= M_n \end{aligned}$$

$$f(n+1) - f(n) = 3X_n$$

$$f(n) = 3 \sum_{i=1}^{n-1} X_i$$

Polya Urn 生成 $U(0, 1)$

例6.6 (Polya坛子抽样模型)

考虑一个装有红、黄两色球的坛子. 假设最初坛子中装有红、黄两色球各一个, 每次都按如下规则有放回地随机抽取: 如果拿出的是红色的球, 则放回的同时再加入一个同色的球; 如果拿出是黄色的球也采取同样的做法. 以 X_n 表示第 n 次抽取后坛子中的红球数, 则 $X_0 = 1$, 且 $\{X_n\}$ 是一个非时齐的 Markov 链, 转移概率为

$$P\{X_{n+1} = k+1 | X_n = k\} = \frac{k}{n+2}$$
$$P\{X_{n+1} = k | X_n = k\} = \frac{n+2-k}{n+2}.$$

令 M_n 表示第 n 次抽取后红球所占的比例, 则 $M_n = \frac{X_n}{n+2}$, 并且 $\{M_n\}$ 是一个鞅.

5.5 鞅收敛定理

鞅收敛定理说的是在很一般的条件下, 鞅 M_n 会收敛到一个极限随机变量 M_∞ . 我们首先考虑一个特殊的例子, Polya 坛子 (5.2 节例 4). 在这种情形下 M_n 是第 n 次摸球后坛中红球所占的比例. 当 n 变大时, 这个比例会如何变化呢? 在习题 5.12 中证明了 M_n 的分布对于较大 n 值会近似于 $[0, 1]$ 上的均匀分布. 因此我们会想: 红球所占的比例会在 0 和 1 之间无限地跳跃吗? 又或者这个比例最终会到达一个特定值吗? 接下来我们将证明后者是成立的.

设 $0 < a < b < \infty$ 且 $M_n < a$, T 为停时

$$T = \min\{j: j \geq n, M_j \geq b\}, \text{ 从 } a \text{ 开始计时}$$

令 $T_m = \min\{T, m\}$, 则对 $m > n$, 由可选抽样定理知

有界停时

$$E(M_{T_m}) = M_n < a.$$

但是

$$a > E(M_{T_m}) \geq E(M_{T_m} I\{T \leq m\}) = \overset{\text{def}}{E(M_T I\{T \leq m\})} \geq bP\{T \leq m\}.$$

所以,

$$P\{T \leq m\} < \frac{a}{b}.$$

116

由于上式对所有的 m 都成立, 从而

$$P\{T < \infty\} \leq \frac{a}{b}.$$

这说明至少以概率 $1 - (\frac{a}{b})$ 红球的比例永远不会超过 b . 现在假设红球的比例确定超过了 b , 那么它能够再一次降回到 a 以下的概率是多少? 同样的讨论应用于绿球的比例, 则降到 a 以下的概率最大为 $\frac{(1-b)}{(1-a)}$. 继续同样的讨论, 我们可以知道, 从 a 出发超过 b , 再小于 a , 再大于 b , 再小于 a , 循环 n 次的概率为

$$\text{利用独立性} \left(\frac{a}{b}\right) \left(\frac{1-b}{1-a}\right) \left(\frac{a}{b}\right) \left(\frac{1-b}{1-a}\right) \cdots \left(\frac{a}{b}\right) \left(\frac{1-b}{1-a}\right) = \left(\frac{a}{b}\right)^n \left(\frac{1-b}{1-a}\right)^n,$$

当 $n \rightarrow \infty$ 时此概率趋于 0, 从而它是有上界的. 因此, 这一比例不会在 a 和 b 之间无限地跳跃. w.p. 0
由于 a, b 是任意的, 这表明该比例不会在任意两个数之间无限地跳跃, 换言之, 极限

$$M_\infty = \lim_{n \rightarrow \infty} M_n$$

存在. 这一极限 M_∞ 是随机变量; 不难证明 (见习题 5.12) M_∞ 服从 $[0, 1]$ 上的均匀分布.

证明 $U(0, 1)$: 用归纳法易得每个点的概率是相等的

$$\text{若 } P\left(M_n = \frac{k}{n+2}\right) = \frac{1}{n+1}$$

$$\text{则 } P\left(M_{n+1} = \frac{k}{n+3}\right) = P(X_{n+1} = k) = \frac{1}{n+1} \left(\frac{n+2-k}{n+2} + \frac{k-1}{n+2} \right) = \frac{1}{n+2}$$

布朗运动B.M. 连续时间连续状态

标准布朗运动S.B.M.

标准表示是 $B(t, \omega)$ 但也可以写作 $B(t), B_t$

经典定义

对于一个随机过程 $B(t, \omega)$:

1. 标准正态: $B(t) \sim N(0, t)$
2. 独立增量: $B(t) - B(s) \sim N(0, t - s)$
3. 连续轨迹: $B(t, \omega)$ 关于 t 是连续的

基于高斯过程的定义

对于一个随机过程 $B(t)$:

1. $B(0) = 0$
2. $B(t)$ 是一个高斯过程:任意时点的联合分布都是正态分布
3. $E(B(t)B(s)) = \min\{t, s\} \rightarrow t > s : E(B(t-s)B(s)) = 0 \rightarrow$ 独立增量
正态分布前提下, 独立与不相关等价

生成S.B.M.

1. $X_t = -B_t$
2. $X_t = B_{t+t_0} - B_{t_0}$ 平移不变性
3. $X_t = CB\left(\frac{t}{c^2}\right)$ 刻度不变性
4. $X_t = tB\left(\frac{1}{t}\right)$ 时间逆转, 注意 $\lim_{t \rightarrow 0^+} tB\left(\frac{1}{t}\right) = 0$ S.B.M. 阶数小于1

基本性质

1. 布朗运动具有**鞅**性(零期望增量: 增量分布(正态)的对称性)
2. 布朗运动具有**马尔可夫**性(由于独立增量性: 充分条件)
所以, 布朗运动拥有前面所学的关于一个随机过程的绝大部分性质, 十分完美

运动轨迹的性质

一句话总结：不光滑，但至少是连续的

轨迹的平方变差收敛

要证明： $[0, t]$ 区间内的轨迹 $B(t)$ 对任一分划 $\{t_i\}$ 满足：

$$\lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n (B(t_i) - B(t_{i-1}))^2 \xrightarrow{\mathcal{L}^2} t$$

注意这里的收敛方式是 \mathcal{L}^2

即证： $E \left[\lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n (B(t_i) - B(t_{i-1}))^2 - t \right]^2 = 0$ (作业题)

轨迹非有界变差(FV)，也就是不收敛

$$\sum_{i=1}^n (B(t_i) - B(t_{i-1}))^2 \leq \max_i |B(t_i) - B(t_{i-1})| \sum_{i=1}^n (B(t_i) - B(t_{i-1}))$$

$$\leq \max_i |B(t_i) - B(t_{i-1})| V_0^t, \quad V_0^t = \sup \sum_{i=1}^n (B(t_i) - B(t_{i-1}))$$

如果 $B(t)$ 是 FV, 那么依据 $B(t)$ 的**一致连续性**，不等式右侧收敛到 0，而左侧收敛到 t ，矛盾

FREE 轨道连续性的刻画，Hölder 连续

FREE 强马尔可夫性

给定一个有限停时 τ , 定义：

$$\tilde{B}(t) = 2B(t \wedge \tau) - B(t) = \mathbb{1}_{(0, \tau)} B(t) + \mathbb{1}_{\tau, \infty} (2B(\tau) - B(t))$$

* $\tilde{B}(t)$ 也是一个布朗运动，而且 $(\tilde{B}, \tau), (B, \tau)$ 同分布

FREE 反射原理

此时我们给定感兴趣的状态 a , 定义停时 $T_a = \inf_t \{B_t = a\} \stackrel{\text{连续变化}}{=} \inf_t \{B_t \geq a\}$

我们还可以基于布朗运动定义最大值过程 $S(t) = \sup_{s \leq t} B(s)$, 则 $T_a = \inf_t \{S_t \geq a\}$

反射原理： $P(S_t \geq a) = P(T_a \leq t) \stackrel{\text{待证}}{=} 2P(B_t \geq a) = P(|B_t| \geq a)$

由此可以推出 $P(T_a \leq t) = 2P(B_t > a) = \int_a^\infty \frac{1}{\sqrt{2\pi t}} e^{-\frac{x^2}{2t}} dx$

从而可以得到pdf: $f_a(t) = \frac{a}{\sqrt{2\pi t^3}} e^{-\frac{a^2}{2t}}$

$$\begin{aligned}
 \textcircled{2} \text{ 求 } T_a \text{ 的 pdf: 已知 } P(T_a \leq t) &= 2 \int_a^\infty \frac{1}{\sqrt{2\pi t}} e^{-\frac{x^2}{2t}} dx \\
 \therefore f_{T_a}(t) &= \frac{d}{dt} P(T_a \leq t) = \frac{d}{dt} \left(2 \int_a^\infty \frac{1}{\sqrt{2\pi t}} e^{-\frac{x^2}{2t}} dx \right) \\
 u = \frac{x}{\sqrt{2t}} &= \frac{1}{\sqrt{2t}} \int_a^\infty e^{-\frac{u^2}{2}} (u^2 - 1) du \\
 \int e^{-\frac{u^2}{2}} (u^2 - 1) du &= -\int \left(\frac{u^3}{3} \right) de^{-\frac{u^2}{2}} \\
 &= \int \left(1 + \frac{1}{u^2} \right) e^{-\frac{u^2}{2}} du - (u - \frac{1}{u}) e^{-\frac{u^2}{2}} \\
 &= \int e^{-\frac{u^2}{2}} du - \int e^{-\frac{u^2}{2}} d\frac{1}{u} - (u - \frac{1}{u}) e^{-\frac{u^2}{2}} \\
 &= \int e^{-\frac{u^2}{2}} du - \frac{1}{u} e^{-\frac{u^2}{2}} - \int e^{-\frac{u^2}{2}} du - (u - \frac{1}{u}) e^{-\frac{u^2}{2}} \\
 &= -\frac{1}{u} e^{-\frac{u^2}{2}} \\
 \therefore \text{上式} &= \frac{1}{\sqrt{2\pi t}} \left(-\frac{1}{u} e^{-\frac{u^2}{2}} \Big|_{\frac{a}{\sqrt{2t}}}^\infty \right) = \frac{a}{\sqrt{2\pi t^3}} e^{-\frac{a^2}{2t}}
 \end{aligned}$$

随机积分(Itô积分)

被积过程是鞅过程的Itô积分

★虽然现在的数学背景变了，但是我们定义积分的过程依旧：

分划区间-小区间取点-求和-取极限，若极限存在则定义ta为积分结果

只不过现在**积分的对象**是随机过程，**被积分的过程**是随机过程，**积分得到的结果**是随机变量(视为定积分)/随机过程(视为变限积分)……

由于**随机性**，我们在小区间上的取点会影响到最后的积分结果，以及并不是所有的随机过程都能积出一个好性质的结果。所以我们加入了一些限定：我们这里只研究**鞅过程上的随机积分**，且定义我们的**取点只能取区间(时段)的左端点**。由此给出随机积分的定义式：

$$\int_0^t \Phi(s) dM(s) = \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n \Phi(t_{i-1})(M(t_i) - M(t_{i-1}))$$

与离散情况下类似，可以证明 $\Psi(t)$ 是一个鞅 毕竟本质就是一个连续的鞅差变换 (只不过这里的收敛形式还不太清楚，需要补充)

被积过程是S.B.M的Itô积分

$$\Psi(t) \stackrel{\text{def}}{=} \int_0^t \Phi(s) dB(s) = \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n \Phi(t_{i-1})(B(t_i) - B(t_{i-1}))$$

例子:

$$\begin{aligned} \int_0^t \Psi(s) dB(s), \Psi(t) \text{非随机} \\ = \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n \Psi(t_{i-1})(B(t_i) - B(t_{i-1})) \end{aligned}$$

注意到布朗运动满足独立增量性, 这个积分可以看做 n 个独立, 服从 $N(0, \Psi^2(t_{i-1})(t_i - t_{i-1}))$ 的正态随机变量的和, 由正态分布的性质可知, 这个积分服从正态分布

$$N\left(0, \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n \Psi(t_{i-1})^2(t_i - t_{i-1}) = \int_0^t \Psi(s) ds\right)$$

例子:

$$\begin{aligned} \int_0^t B(s) dB(s) &= \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n B(t_{i-1})(B(t_i) - B(t_{i-1})) \\ &= \frac{1}{2} \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n [2B(t_{i-1})B(t_i) - 2B(t_{i-1})^2] \\ &= \frac{1}{2} \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n [(-B(t_i)^2 + 2B(t_{i-1})B(t_i) - B(t_{i-1})^2) + (B(t_i)^2 - B(t_{i-1})^2)] \\ &= \frac{1}{2} \left(\lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n [(B(t_i)^2 - B(t_{i-1})^2)] - \sum_{i=1}^n [B(t_i) - B(t_{i-1})]^2 \right) \\ &= \frac{1}{2} (B(t)^2 - t) \end{aligned}$$

相比之下, 对于实数域上的积分 $\int_0^t f(s) df(s) = \frac{1}{2} f(t)^2, f(0) = 0$

如果我们小区间取的是区间中点, 那么最终积分的结果不一样:

$$\begin{aligned} \int_0^t B(s) dB(s) &= \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n \frac{1}{2} (B(t_i) + B(t_{i-1}))(B(t_i) - B(t_{i-1})) \\ &= \frac{1}{2} B(t)^2 \end{aligned}$$

随机积分的平方变差 $\langle \Psi_t \rangle$

泛函分析观点下的随机积分 (一): L2鞅与变差 - 知乎

这个概念原本是基于鞅定义的: 对一个鞅 $M(t)$:

$$\text{def} : \langle M(t) \rangle = \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n (M(t_i) - M(t_{i-1}))^2$$

现在分别考虑S. B. M. 上的/一般鞅上的随机积分 $\Psi(t)|B(t)$, $\Psi(t)|M(t)$:

$$\begin{aligned} \langle \Psi_t \rangle | B(t) &= \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n \left(\int_{t_{i-1}}^{t_i} \Phi(s) dB(s) \right)^2 \\ &\approx \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n (\Phi^2(t_{i-1})(B(t_i) - B(t_{i-1}))^2) \\ &\approx \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n \Phi^2(t_{i-1})(t_i - t_{i-1}) \\ &= \int_0^t \Phi^2(s) ds \end{aligned}$$

$$\begin{aligned} \langle \Psi_t \rangle | M(t) &= \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n \left(\int_{t_{i-1}}^{t_i} \Phi(s) dM(s) \right)^2 \\ &\approx \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n (\Phi^2(t_{i-1})(M(t_i) - M(t_{i-1}))^2) \\ &= \int_0^t \Phi^2(s) d\langle M(s) \rangle \end{aligned}$$

总结: 随机积分的平方变差 $\langle \Psi_t \rangle = \int_0^t \Phi^2(s) d\langle M(s) \rangle$

两个鞅的交互变差

对于两个鞅 M_t, N_t , 定义交互变差

$$\langle M_t, N_t \rangle \stackrel{\text{def}}{=} \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n (M(t_i) - M(t_{i-1}))(N(t_i) - N(t_{i-1}))$$

交互变差性质:

1. 鞅性
2. 等于0的充分条件: M, N 相互独立, 或者其中一个是连续FV过程

Itô公式

我们这里考虑积分对象是被积过程 $M(t)$ 的函数 $f(M(t))$ (也就是一个可测的随机对象)。如果我们想用变限随机积分表示被积过程，我们需要将被积过程分划，并在每一小段进行 $Taylor$ 展开。

在实数域上，这一过程如下：假设 $f(\cdot)$ 一阶可微

$$\begin{aligned}f(t) &= f(0) + \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n f(t_{i-1}) - f(t_i) \\&= f(0) + \lim_{\|\Delta\| \rightarrow 0} \sum f'(t_{i-1})(t_{i-1} - t_i) + \frac{1}{2} \lim_{\|\Delta\| \rightarrow 0} \sum f''(t_{i-1})(t_{i-1} - t_i)^2 + \dots \\&= f(0) + \int_0^t f'(s) ds + \int_0^t f''(s) [ds]^2 \\&= f(0) + \int_0^t f'(s) ds\end{aligned}$$

但是在随机积分中，被积过程的不光滑性会带来不一样的结果。

一维

假设 $f(\cdot)$ 二阶可微：如果被积过程是S. B. M.

$$\begin{aligned}f(B_t) &= f(0) + \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n f(B_{t_i}) - f(B_{t_{i-1}}) \\&= f(0) + \lim_{\|\Delta\| \rightarrow 0} \sum f'(B_{t_{i-1}})(B_{t_{i-1}} - B_{t_i}) + \frac{1}{2} \lim_{\|\Delta\| \rightarrow 0} \sum f''(B_{t_{i-1}})(B_{t_{i-1}} - B_{t_i})^2 \\&= f(0) + \int_0^t f'(B_s) dB_s + \int_0^t f''(B_s) [(dB_s)^2] \\&= f(0) + \int_0^t f'(B_s) dB_s + \int_0^t f''(B_s) ds\end{aligned}$$

如果被积过程是一般鞅：

$$\begin{aligned}f(M_t) &= f(0) + \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n f(M_{t_i}) - f(M_{t_{i-1}}) \\&= f(0) + \lim_{\|\Delta\| \rightarrow 0} \sum f'(M_{t_{i-1}})(M_{t_{i-1}} - M_{t_i}) + \frac{1}{2} \lim_{\|\Delta\| \rightarrow 0} \sum f''(M_{t_{i-1}})(M_{t_{i-1}} - M_{t_i})^2 \\&= f(0) + \int_0^t f'(M_s) dM_s + \int_0^t f''(M_s) [(dM_s)^2] \\&= f(0) + \int_0^t f'(M_s) dM_s + \int_0^t f''(M_s) d\langle M(s) \rangle\end{aligned}$$

二维→多维

假设 $f(\cdot, \cdot)$ 有二阶连续偏导数：考虑被积过程是两个鞅 M_t, N_t

$$\begin{aligned}
& f(M_t, N_t) \\
&= f(0, 0) + \lim_{\|\Delta\| \rightarrow 0} \sum_{i=1}^n f(M_{t_i}, N_{t_i}) - f(M_{t_{i-1}}, N_{t_{i-1}}) \\
&= f(0) + \left[\int_0^t f_M(M_s) dM_s + \int_0^t f_N(N_s) dN_s \right] + \\
&\quad \frac{1}{2} \left[\int_0^t f_{MM}(M_s) [(dM_s)^2] + \int_0^t f_{NN}(N_s) [(dN_s)^2] + 2 \int_0^t f_{MN}(s) [(dM_s dN_s)] \right] \\
&= f(0) + \left[\int_0^t f_M(M_s) dM_s + \int_0^t f_N(N_s) dN_s \right] + \\
&\quad \frac{1}{2} \left[\int_0^t f_{MM}(M_s) d\langle M(s) \rangle + \int_0^t f_{NN}(N_s) d\langle N(s) \rangle + 2 \int_0^t f_{MN}(s) d\langle M(s)N(s) \rangle \right]
\end{aligned}$$

如果 $N(t)$ 是一个有界变差过程(或者是非随机的)，那么结果变为：

$$f(M_t, N_t) = f(0) + \left[\int_0^t f_M(M_s) dM_s + \int_0^t f_N(N_s) dN_s \right] + \frac{1}{2} \int_0^t f_{MM}(M_s) d\langle M(s) \rangle$$

Itô diffusion的随机微分方程

对于形如 $X_t = f(B_t)$ 的随机过程，我们用伊藤积分表示为：

$$X_t = f(B_t) = f(0) + \int_0^t f'(B_s) dB_s + \int_0^t f''(B_s) ds$$

对这个式子微分就可以得到一个随机微分方程(SDE)：

$$dX_t = f'(B_t)dB_t + f''(B_t)dt$$

一般地，我们可以写成：

$$dX_t = \mu(X_t)dt + \sigma(X_t)dB_t$$

这就是Itô diffusion的随机微分方程的通式， $\mu(\cdot)$ 代表漂移项； $\sigma(\cdot)$ 代表扩散项

向后/向前方程

[C-K方程, Kolmogorov前后向方程与主方程 - 知乎](#)

[什么是Fokker-Planck方程? - 知乎](#)

除了随机过程本身，我们也关注其转移概率密度函数的表达式，ta的定义如下：

$$\text{def} : P(t, x, y) \rightarrow P(t, x, A) = P_x(X_t \in A) = \int_A p(t, x, y) dy$$

ta满足什么样的微分方程？这就是“向后/向方程”所要描述的目标

证明过程(重在欣赏)

我们在这里引入一族性质良好的“检验函数” $f(\cdot)$ 并定义：

$$p_t f(x) = E_x f(x_t) = u(t, x)$$

$$\star \text{ 其中: } E_x f(x_t) = \int_{\mathbb{R}} f(y) p(t, x, y) dy$$

$$\begin{aligned} \frac{dp_t f(x)}{dt} &= \lim_{h \rightarrow 0} \frac{u(t+h, x) - u(t, x)}{h} \\ &= \lim_{h \rightarrow 0} \frac{E_x [E_x(f_{t+h}(x) | \mathcal{F}_h)] - u(t, x)}{h} \\ &= \lim_{h \rightarrow 0} \frac{E_x [E_{x_h}(f_t(x))] - u(t, x)}{h} \quad (\text{马氏性, 对起点}) \\ &= \lim_{h \rightarrow 0} \frac{E_x [u(t, x_h) - u(t, x)]}{h} \\ &= \lim_{h \rightarrow 0} \frac{E_x \left(\int_0^t u_x(t, x_s) dx_s + \frac{1}{2} \int_0^t u_{xx}(t, x_s) d\langle x_s \rangle \right)}{h} \end{aligned}$$

$$dx_t = b(x_t)dt + \sigma(x_t)dB_t$$

$$d\langle x_t \rangle = \sigma^2(x_t)dt$$

$$\begin{aligned} &= \lim_{h \rightarrow 0} \frac{E_x \left(\int_0^t u_x(t, x_s) (b(x_s)ds + \sigma(x_s)dB_s) + \frac{1}{2} \int_0^t u_{xx}(t, x_s) \sigma^2(x_s) ds \right)}{h} \\ &= \lim_{h \rightarrow 0} \frac{E_x \left(\int_0^t [u_x(t, x_s)b(x_s) + \frac{1}{2}\sigma^2(x_s)u_{xx}(t, x_s)] ds + \int_0^t u_x(t, x_s)\sigma(x_s) dE \right)}{h} \\ &= \lim_{h \rightarrow 0} \frac{E_x \left(\int_0^t [u_x(t, x_s)b(s) + \frac{1}{2}\sigma^2(x_s)u_{xx}(t, x_s)] ds \right)}{h} \quad (\text{最后一项是鞅}) \\ &= b(x)u_x(t, x) + \frac{1}{2}\sigma^2(x)u_{xx}(t, x) \\ &\stackrel{\Delta}{=} Au(t, x) \end{aligned}$$

由此得到：

$$\begin{aligned}
\frac{\partial u(t, x)}{\partial t} &= Au(t, x) \\
&\left(= \int_{\mathbb{R}} f(y) \frac{\partial p(t, x, y)}{\partial t} dy \right) (\text{按照定义直接求导}) \\
&= Ap_t f(x) \\
&= A \int_{\mathbb{R}} f(y) p(t, x, y) dy \\
&\left(= \int_{\mathbb{R}} f(y) Ap(t, x, y) dy \right) (\text{通过积分变换得到})
\end{aligned}$$

由于 $f(\cdot)$ 的任意性，可得向后方程

$$\frac{\partial p(t, x, y)}{\partial t} = Ap(t, x, y) = b(x)p_x(t, x, y) + \frac{1}{2}\sigma^2(x)p_{xx}(t, x, y)$$

而对于向前方程，我们有

$$\begin{aligned}
u(t, x) &= E_x(f(x_t)) = f(x) + E_x \int_0^t Af(x_s) ds \\
&= f(x) + \int_0^t E_x Af(x_s) ds \\
&= f(x) + \int_0^t \int_{\mathbb{R}} Af(y)p(s, x, y) dy ds
\end{aligned}$$

对于 t 求导：

$$\begin{aligned}
\frac{\partial u(t, x)}{\partial t} &= \int_{\mathbb{R}} f(y) \frac{\partial p(t, x, y)}{\partial t} dy \\
&= \int_{\mathbb{R}} Af(y)p(t, x, y) dy \\
&= - \int_{\mathbb{R}} f(y)(b(y)p(t, x, y))' dy + \frac{1}{2} \int_{\mathbb{R}} (\sigma^2(y)p(t, x, y))'' dy
\end{aligned}$$

由于 $f(\cdot)$ 的任意性，可得向前方程

$$\frac{\partial u(t, x)}{\partial t} = -(b(y)p(t, x, y))' + \left(\frac{1}{2}\sigma^2(y)p(t, x, y)\right)''$$

总结：

$$\begin{aligned} \text{向后方程: } \frac{\partial P(t, x, y)}{\partial t} &= AP(t, x, y) = b(x) \frac{\partial P(t, x, y)}{\partial x} + \frac{1}{2} \sigma^2(x) \frac{\partial^2 P(t, x, y)}{\partial x^2} \\ \text{向前方程: } \frac{\partial P(t, x, y)}{\partial t} &= A^* P(t, x, y) = -\frac{\partial b(y) P(t, x, y)}{\partial y} + \frac{\partial^2 \left[\frac{1}{2} \sigma^2(y) P(t, x, y) \right]}{\partial y^2} \end{aligned}$$

实例: Black-scholes 定价公式

假设市场上有两种资产:

$$\begin{aligned} dS_0(t) &= rS_0(t)dt \\ dS_1(t) &= b(S_t)dt + \sigma(X(t))dB_t \\ X(t) &= \delta_0(t)S_0(t) + \delta_1(t)S_1(t) \end{aligned}$$

设 $b(x) = \mu x, \sigma(x) = \sigma x$:

$$dX(t) = rX(t)dt + ((\mu - r)\delta_1(t)S_1(t))dt + \sigma\delta_1(t)S_1(t)dB_t$$

$$X(t) = X_0 e^{rt} + \int_0^t e^{r(t-x)} (\mu - r) \delta_1(x) S_1(x) dx + \int_0^t e^{r(t-x)} \sigma \delta_1(x) S_1(x) dB_x$$

折现可以得到:

$$X_t e^{-rt} = X_0 + \int_0^t e^{-rx} (\mu - r) \delta_1(x) S_1(x) dx + \int_0^t e^{-rx} \sigma \delta_1(x) S_1(x) dB_x$$

现在引入第三种资产: 看涨期权

对于看涨期权 (T, K, S_T) 其当前价值 $\overset{\Delta}{=} c(0, S_0) = (S_t - k)^+$

下面我们默认: $S_1(t) \equiv S(t)$

一方面, 根据伊藤公式:

$$d(e^{-rt}C(t, S_t)) = e^{-rt}dC(t, S_t) - re^{-rt}C(t, S_t)dt$$

$$dC(t, S_t) = C_t(t, S_t)dt + C_s(t, S_t)dS_t + \frac{1}{2}C_{ss}(t, S_t)d\langle S \rangle_t$$

$$dS_t = \mu S_t dt + \sigma S_t dB_t$$

$$d\langle S \rangle_t = \sigma^2 S_t^2 dt$$

$$dC(t, S_t) = \left[C_t(t, S_t) + \mu S_t C_s(t, S_t) + \frac{\sigma^2}{2} S_t^2 C_{ss}(t, S_t) \right] dt + C_s(t, S_t) \sigma S_t dB_t$$

$$d(e^{-rt}C(t, S_t)) = e^{-rt} \left[C_t(t, S_t) + \mu S_t C_s(t, S_t) + \frac{\sigma^2}{2} S_t^2 C_{ss}(t, S_t) - rC(t, S_t) \right] dt + e^{-rt} C_s(t, S_t) \sigma S_t dB_t$$

另一方面，由于**无套利原则**：

$$d(e^{-rt}C(t, S_t)) = e^{-rt}(\mu - r)\delta_1(t)S_1(t)dt + e^{-rt}\sigma\delta_1(t)S_tdB_t$$

$$X_t = C(t, S_t) \iff X_0 = C(0, S_0)$$

另一方面，由于**风险对冲**： $C_s(t, S_t) = \delta_1(t)$

$$C_t(t, S_t) + \mu S_t C_s(t, S_t) + \frac{\sigma^2}{2} S_t^2 C_{ss}(t, S_t) - rC(t, S_t) = (\mu - r)C_s(t)S_t$$

可以得到一个PDE：

$$C_t(t, S_t) + rC_s(t, S_t)S_t + \frac{\sigma^2}{2} S_t^2 C_{ss}(t, S_t) - rC(t, S_t) = 0$$

$$s.t. C(T, X) = (X - K)^+$$

根据Feynman-Kac公式，可以计算出 $C(t, x) = E_x(S_T - k)^+ e^{-r(T-t)}$

由于 $S_t = x \exp\left(\sigma B_t + \left(\mu - \frac{\sigma^2}{2}\right)t\right)$ 对数正态

可以算出

$$\begin{aligned}
C(0, X) &= e^{-rt} \int_{\mathbb{R}} \left(x \exp \left(\sigma y + \left(\mu - \frac{\sigma^2}{2} \right) T \right) - K \right)^+ \frac{1}{\sqrt{2\pi t}} e^{-y^2/2T} dy \\
&= e^{-rt} \int_d^\infty \left(x \exp \left(\sigma y + \left(\mu - \frac{\sigma^2}{2} \right) T \right) - K \right)^+ \frac{1}{\sqrt{2\pi t}} e^{-y^2/2T} dy \\
d : x \exp \left(\sigma d + \left(\mu - \frac{\sigma^2}{2} \right) T \right) &= 0 \\
&= x e^{(\mu - \sigma^2/2 - r)T} \int_d^\infty e^{\sigma y} \frac{1}{\sqrt{2\pi t}} e^{-y^2/2T} dy - K e^{-rT} \int_d^\infty \frac{1}{\sqrt{2\pi t}} e^{-y^2/2T} dy \\
&= (x e^{(\mu - r)T} - K e^{-rT})(1 - \Phi(d)) \stackrel{\mu=r}{=} (X - K e^{-rT})(1 - \Phi(d))
\end{aligned}$$

这就是最终的期权定价公式

验证一些结论

0. U. 对于一个SDE $dX(t) = -\mu X_t dt + \sigma dB(t)$ 存在解:

$$\begin{aligned}
X(t) &= e^{-\mu t} \left(X_0 + \int_0^t \sigma e^{\mu s} dB(s) \right) \\
dX(t) &= -\mu X(t) dt + e^{-\mu t} (\sigma e^{\mu t} dB(t) - \mu \int_0^t \sigma e^{\mu s} dB(s) dt) \\
&= -\mu e^{-\mu t} \left[(X(0) + \int_0^t \sigma e^{\mu s} dB(s)) \right] dt + \sigma dB(t) \\
&= -\mu X(t) dt + \sigma dB(t)
\end{aligned}$$

Geo B. M. 对于一个SDE $dX(t) = \mu X_t dt + \sigma X(t) dB(t)$ 存在解:

$$\begin{aligned}
X(t) &= e^{\mu t} \left(X_0 + \int_0^t \sigma e^{-\mu s} X(s) dB(s) \right) \\
dX(t) &= \mu X(t) dt + e^{\mu t} (\sigma e^{-\mu t} X(t) dB(t) + \mu \int_0^t \sigma e^{-\mu s} X(s) dB(s) dt) \\
&= \mu e^{\mu t} \left[(X(0) + \int_0^t \sigma e^{-\mu s} X(s) dB(s)) \right] dt + \sigma X(t) dB(t) \\
&= \mu X(t) dt + \sigma dB(t)
\end{aligned}$$

这一结论对于一般的非齐次一阶SDE均生效

to be continued