

# 高计(考完啦)

## 题目整理

### 第一次作业

- 对于简单线性模型:  $y_i = \beta_1 + \beta_2 x_{i2} + \epsilon_i$ , 估计  $\beta_1, \beta_2$ ; 考虑新的样本  $(y_{n+1}, x_{n+1})$ , 求  $y_{n+1}$  的预测方差  $Var(y_{n+1} - \hat{y}_{n+1} | X, x_{n+1})$  的表达式, 并求其最小值及取值条件
  - 最小化的条件是  $x_{n+1} = \bar{X}$ , 即新样本落在被估计样本的均值时估计方差最小。
- 证明: 对于OLS模型, 解释变量个数越多, 残差平方和  $e'e$  越小,  $R^2$  越大
  - 在  $(k+1)$  元模型视角下  $(k)$  元模型可视为一簇特例:  $\{\beta : \beta_{k+1} = 0\}$
  - 证明: 定义  $\mathbf{e}_k$  是  $k$  元模型下的残差, 我们要证明的是  $\mathbf{e}'_k \mathbf{e}_k > \mathbf{e}'_{k+1} \mathbf{e}_{k+1}$ , 我们可以去证明  $\mathbf{e}_{k+1} \perp (\mathbf{e}_k - \mathbf{e}_{k+1})$  (直角三角形)
  - 为了证明正交, 我们要借助消灭矩阵:
$$\begin{aligned} \mathbf{e}'_{k+1} \cdot (\mathbf{e}_k - \mathbf{e}_{k+1}) &= \mathbf{y}' \mathbf{M}'_{k+1} \mathbf{M}_{k+1} \mathbf{y} - \mathbf{y}' \mathbf{M}'_{k+1} \mathbf{M}_k \mathbf{y} \\ &= \mathbf{y}' \mathbf{M}_{k+1} \mathbf{y} - \mathbf{y}' \mathbf{M}_{k+1} \mathbf{y} = 0 \end{aligned}$$
  - 消灭矩阵的含义: 保留一个向量与  $\mathbf{X}$  各个分量都正交的部分, 这解释了3中  $\mathbf{M}'_{k+1} \mathbf{M}_k = \mathbf{M}'_{k+1}$
- 若DGP(data generating process)为:  $y = \beta_1 x_1 + \beta_2 x_2 + \epsilon_i$ , 而我们估计的模型为  $y = \gamma_1 x_1 + u_i$ , 证明:  $\gamma_{OLS}$  对于  $\beta_1$  是有偏估计
- 若DGP(data generating process)为:  $y = \beta_1 x_1 + \epsilon_i$ , 而我们估计的模型为  $y = \gamma_1 x_1 + \gamma_2 x_2 + u_i$ , 证明:  
 $\gamma_{1,OLS}$  对于  $\beta_1$  是无偏估计, 但是  $Var(\gamma_{1,OLS} | X) > Var(\beta_{1,OLS} | X)$ 
  - 一般化的计算(利用分块矩阵, 把矩阵整体放入线性方程组中, 简化方程结构)
  - 定义  $\mathbf{X} = (\mathbf{X}_1 : \mathbf{X}_2)$   $\mathbf{b} = (\mathbf{b}_1 : \mathbf{b}_2)'$   $\beta = (\beta_1 : \beta_2)'$
  - OLS一阶条件方程组可以写成:

$$(\mathbf{X}'_1 : \mathbf{X}'_2)' (\mathbf{X}_1 : \mathbf{X}_2) (\mathbf{b}_1 : \mathbf{b}_2)' = (\mathbf{X}'_1 : \mathbf{X}'_2)' \mathbf{y}$$

即:

$$\begin{cases} \mathbf{X}'_1 \mathbf{X}_1 \mathbf{b}_1 + \mathbf{X}'_1 \mathbf{X}_2 \mathbf{b}_2 = \mathbf{X}'_1 \mathbf{y} \\ \mathbf{X}'_2 \mathbf{X}_1 \mathbf{b}_1 + \mathbf{X}'_2 \mathbf{X}_2 \mathbf{b}_2 = \mathbf{X}'_2 \mathbf{y} \end{cases}$$

4. 第一个方程左乘  $\mathbf{X}_1(\mathbf{X}_1'\mathbf{X}_1)^{-1}$  得到:  $\mathbf{X}_1\mathbf{b}_1 + \mathbf{P}_1'\mathbf{X}_2\mathbf{b}_2 = \mathbf{P}_1'\mathbf{y}$
5. 带入到第二个方程: 对称地, 可以得到  $\mathbf{b}_1$   
 $\mathbf{X}_2'(\mathbf{y} - \mathbf{X}_2\mathbf{b}_2) + \mathbf{X}_2'\mathbf{X}_2\mathbf{b}_2 = \mathbf{X}_2'\mathbf{y} \quad \mathbf{b}_2 = (\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{M}_1\mathbf{y}$
6.  $\mathbf{b}_2 = (\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{M}_1\mathbf{y} = (\mathbf{X}_2'\mathbf{M}_1'\mathbf{M}_1\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{M}_1\mathbf{y}$   
 $= (\mathbf{X}_{2\text{to}1}'\mathbf{X}_{2\text{to}1})^{-1}\mathbf{X}_{2\text{to}1}'\mathbf{y}$   $\mathbf{X}_{2\text{to}1}$  表示  $\mathbf{X}_2$  中与  $\mathbf{X}_1$  各个分量都正交的部分
7.  $Var(\mathbf{b}_1|\mathbf{X}_1, \mathbf{X}_2) - Var(\mathbf{b}_1^*|\mathbf{X}_1, \mathbf{X}_2) = \sigma^2((\mathbf{X}_1'\mathbf{M}_2\mathbf{X}_1)^{-1} - (\mathbf{X}_1'\mathbf{X}_1)^{-1})$
8. 定理: 已知  $\mathbf{B}, \mathbf{A}$  半正定:  $(\mathbf{B}^{-1} - \mathbf{A}^{-1})$  半正定 *iff*  $\mathbf{A} - \mathbf{B}$  半正定
9. 因为  $\mathbf{X}_1'\mathbf{X}_1 - \mathbf{X}_1'\mathbf{M}_2\mathbf{X}_1 = \mathbf{X}_1'\mathbf{P}_2\mathbf{X}_1 = (\mathbf{P}_2\mathbf{X}_1)'(\mathbf{P}_2\mathbf{X}_1) \geq 0$  得证

## 期中考试

- 在大样本模型下考虑  $\sqrt{n}(s^2 - E(\epsilon^2))$  的渐近分布

$$s^2 = \frac{1}{n} \sum_{i=1}^n e_i^2$$

$$= \frac{1}{n} \sum_{i=1}^n \epsilon_i^2 + 2(b - \beta)' \bar{g} + (b - \beta)' \mathbf{S}_{xx} (b - \beta)$$

$$\sqrt{n}(s^2 - E(\epsilon^2)) = \sqrt{n}\left(\frac{1}{n} \sum_{i=1}^n \epsilon_i^2 - E(\epsilon^2)\right) + 2(b - \beta)' \sqrt{n} \bar{g} + \sqrt{n}(b - \beta)' \mathbf{S}_{xx} (b - \beta)$$

$$\xrightarrow{d} N(0, Var(\epsilon_i^2))$$

$$[\sqrt{n} \bar{g} \xrightarrow{d} N(0, S) \quad (b - \beta) \xrightarrow{p} 0 \quad \sqrt{n}(b - \beta) \xrightarrow{d} N(0, Avar(b))]$$

4. In the restricted least square, the sum of squared residuals is minimized subject to the constraint implied by the null hypothesis  $\mathbf{R}\beta = \mathbf{r}$ . Form the Lagrangian as

$$\mathcal{L} = \frac{1}{2}(\mathbf{y} - \mathbf{X}\tilde{\beta})'(\mathbf{y} - \mathbf{X}\tilde{\beta}) + \lambda'(\mathbf{R}\tilde{\beta} - \mathbf{r}),$$

where  $\lambda$  here is the  $\#r$ -dimensional vector of Lagrange multipliers. Let  $\hat{\beta}$  be the restricted least square estimator of  $\beta$ . It is the solution of the constrained minimization problem.

(a) (10 points) Let  $\mathbf{b}$  be the unconstrained OLS estimator. Show that both  $\hat{\beta} - \mathbf{b}$  and  $\lambda$  can be expressed as the form  $\mathbf{C}_1(\mathbf{R}\mathbf{b} - \mathbf{r})$  and solve the corresponding matrices  $\mathbf{C}_1$ .

(b) (10 points) Let  $\hat{\epsilon} = \mathbf{y} - \mathbf{X}\hat{\beta}$ ,  $\mathbf{e} = \mathbf{y} - \mathbf{X}\mathbf{b}$ , and  $\mathbf{P} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ . Show:  $\hat{\epsilon}'\hat{\epsilon} - \mathbf{e}'\mathbf{e} = \hat{\epsilon}'\mathbf{P}\hat{\epsilon}$ .

(b) 可以移项改为  $\hat{\epsilon}'\mathbf{M}\hat{\epsilon} = \mathbf{e}'\mathbf{e} : \mathbf{M} = \mathbf{I} - \mathbf{P}$ , 这个明显更好证明

$$\hat{\epsilon}'\mathbf{M}\hat{\epsilon} = (\mathbf{M}(\mathbf{y} - \mathbf{X}\hat{\beta}))'(\mathbf{M}(\mathbf{y} - \mathbf{X}\hat{\beta})) = \mathbf{e}'\mathbf{e}$$

因为 $\mathbf{M}$ 矩阵依据OLS方法得到，有着很好的性质 $\mathbf{MX} = \mathbf{0}$ ,  $\mathbf{My} = \mathbf{e}$ ，从而得证

## 第二次作业

hayashi教材

Q4R: 3. 2. 1/3. 2. 2/3. 4. 1

AE:2/3/5

---

## 参考

- 林文夫《计量经济学》
- 洪永淼《高级计量经济学》
- [keep random](#)
- [数理统计](#)
- [多元统计分析学习记录目录 - 知乎 \(zhihu.com\)](#)
- AE答案参考:
  - [第一章答案](#)
  - [第三章答案](#)
  - [第三章答案](#)

## 有限样本OLS

### 有限样本假设

1. 线性模型：总体模型可以表示为： $\mathbf{y} = \mathbf{X}\beta + \epsilon$
2. 严格外生性： $E(\epsilon|\mathbf{X}) = \mathbf{0}$ 
  1.  $E(\epsilon) = \mathbf{0}$
  2.  $E(\mathbf{X}\epsilon) = \mathbf{0}$
  3.  $Cov(\mathbf{X}, \epsilon) = \mathbf{0}$
3. 无多重共线性： $rank(\mathbf{X}) = K \quad w.p.1$ （以概率1）
4. 误差球面方差： $Var(\epsilon|\mathbf{X}) = \sigma^2 \mathbf{I}_n$ 
  1. 同方差： $Var(\epsilon_i|\mathbf{X}) = \sigma^2$
  2. 观测值不相关： $Var(\epsilon_i, \epsilon_j|\mathbf{X}) = 0$
5. 误差正态分布： $\epsilon|\mathbf{X} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ 
  1. 独立随机样本

# OLS代数计算

OLS的目标是：

$$\begin{aligned}\min_{\mathbf{b}} \mathbf{e}'\mathbf{e} &= (\mathbf{y} - \mathbf{X}\mathbf{b})'(\mathbf{y} - \mathbf{X}\mathbf{b}) \\ &= \mathbf{y}\mathbf{y}' - 2\mathbf{y}'\mathbf{X}\mathbf{b} + \mathbf{b}'\mathbf{X}'\mathbf{X}\mathbf{b}\end{aligned}$$

接下来对 $\mathbf{b}$ 求导可以得到：

$$\frac{\partial \mathbf{e}'\mathbf{e}}{\partial \mathbf{b}} = 2((\mathbf{X}'\mathbf{X})\mathbf{b} - \mathbf{X}'\mathbf{y})$$

另上式为0可以得到： $\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{A}_{k \times n}\mathbf{y}$ ，抽样误差

$$\mathbf{b} - \boldsymbol{\beta} = \mathbf{A}\boldsymbol{\epsilon} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\boldsymbol{\epsilon})$$

基于这个表达式得到的OLS渐近偏误可以解释内生性出现时偏误的方向。

## 有限样本OLS性质

### 代数、几何性质

1. 定义投影矩阵： $\mathbf{P} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \mathbf{X}\mathbf{A}$ ：
  1.  $\mathbf{P}$ 对称且二阶幂等
    1. 二阶幂等矩阵具有性质： $tr(\mathbf{P}) = rank(\mathbf{P})$
  2.  $\mathbf{P}\mathbf{X} = \mathbf{X}, \mathbf{P}\mathbf{y} = \mathbf{X}\mathbf{b} = \hat{\mathbf{y}}$
  3. 之所以如此命名是因为 $\mathbf{y}$ 在 $\mathbf{M}$ 作用下被投影到了 $span(\mathbf{X})$ 上
2. 定义消灭矩阵： $\mathbf{M} = \mathbf{I}_n - \mathbf{P}$ 
  1.  $\mathbf{M}$ 对称且二阶幂等
    1. 二阶幂等矩阵具有性质： $tr(\mathbf{P}) = rank(\mathbf{P})$
  2.  $\mathbf{M}\mathbf{X} = \mathbf{0}, \mathbf{M}\mathbf{y} = \mathbf{M}\boldsymbol{\epsilon} = \mathbf{e}$
3.  $\mathbf{X}'\mathbf{e} = 0, \hat{\mathbf{y}}'\mathbf{e} = 0$ 
  1.  $\mathbf{X}'\mathbf{e} = \mathbf{X}'(\mathbf{y} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}) = \mathbf{X}'\mathbf{M}\mathbf{y} = \mathbf{0}$

## 统计性质

### 点估计的性质

1. 无偏性： $E(\mathbf{b}|\mathbf{X}) = \boldsymbol{\beta}$
2. OLS方差： $Var(\mathbf{b}|\mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$   
 $(\mathbf{A}\mathbf{A}' = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}\mathbf{X}'(\mathbf{X}'\mathbf{X})^{-1} = (\mathbf{X}'\mathbf{X})^{-1})$
3. 高马定理：OLS估计量是BLUE：最优线性无偏估计量

1. 线性无偏估计量：在形如 “ $\mathbf{C}\mathbf{y}$  的对  $\beta$  的无偏估计量” 的范围
2. 最优：最小条件协方差阵  $\text{Var}((\mathbf{C} - \mathbf{A})\mathbf{y}|\mathbf{X})$  半正定
3. 证明：考虑  $\mathbf{D} = (\mathbf{C} - \mathbf{A})$ , 则：

1.  $\mathbf{C}\mathbf{y} = \mathbf{D}\mathbf{X}\beta + \mathbf{b} + \mathbf{C}\epsilon$

$$\begin{aligned} E(\mathbf{C}\mathbf{y}|\mathbf{X}) \\ &= E((\mathbf{D}\mathbf{X}\beta + \mathbf{b} + \mathbf{C}\epsilon)|\mathbf{X}) \end{aligned}$$

2.  $= \beta + E((\mathbf{D}\mathbf{X}\beta|\mathbf{X})$   
 $\rightarrow E((\mathbf{D}\mathbf{X}\beta|\mathbf{X}) = 0$   
 $\rightarrow \mathbf{D}\mathbf{X} = 0$

$$\begin{aligned} \text{Var}(\mathbf{C}\mathbf{y}|\mathbf{X}) \\ &= \text{Var}((\mathbf{D} + \mathbf{A})\epsilon|\mathbf{X}) \\ &= \sigma^2((\mathbf{D} + \mathbf{A})(\mathbf{D} + \mathbf{A})') \\ &= \sigma^2(\mathbf{D}\mathbf{D}' + \mathbf{A}\mathbf{A}' + \mathbf{A}\mathbf{D}' + \mathbf{D}\mathbf{A}') \end{aligned}$$

3.  $(\mathbf{D}\mathbf{A}' = \mathbf{D}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = 0)$   
 $= \sigma^2(\mathbf{D}\mathbf{D}' + \mathbf{A}\mathbf{A}')$   
 $= \sigma^2(\mathbf{D}'\mathbf{D} + (\mathbf{X}'\mathbf{X})^{-1})$   
 $\geq \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$

4.  $\text{Cov}(\mathbf{b}, \mathbf{e}|\mathbf{X}) = 0$

$$\begin{aligned} \text{Cov}(\mathbf{b}, \mathbf{e}|\mathbf{X}) \\ &= E((\mathbf{b} - \beta)\mathbf{e}'|\mathbf{X}) \end{aligned}$$

1.  $= E(\mathbf{A}\epsilon(\mathbf{M}\epsilon)'|\mathbf{X})$   
 $= \sigma^2\mathbf{A}\mathbf{M}'$   
 $= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{M}'$   
 $= 0$

5.  $\sigma^2$  的无偏估计  $s^2 = \frac{\mathbf{e}'\mathbf{e}}{n-k}$

1.  $E(\chi_n^2) = n\sigma^2$

$$\begin{aligned} E(\mathbf{e}'\mathbf{e}|\mathbf{X}) \\ &= E(\epsilon'\mathbf{M}\epsilon) \end{aligned}$$

2. 证明：  
 $= \sigma^2 \text{tr}(\mathbf{M})$   
 $= \sigma^2 \text{rank}(\mathbf{M})$   
 $= \sigma^2 \text{rank}(\mathbf{I}_n - \mathbf{P})$   
 $= \sigma^2(n - k)$

## 点估计的条件分布

三大分布具体看 [数理统计](#)

1.  $b|\mathbf{X} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$

1.  $\frac{b-\beta}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})^{-1}}} \sim N(0, 1)$

2.  $(n-k)\frac{s^2}{\sigma^2} | \mathbf{X} \sim \chi_{n-k}^2$  (这里有**前提条件**:  $\mathbf{M}$ 是幂等矩阵)

$$1. \quad (n-k)\frac{s^2}{\sigma^2} = \frac{\epsilon' \mathbf{M} \epsilon}{\sigma^2} \\ = \left(\frac{\epsilon}{\sigma}\right)' \mathbf{M} \left(\frac{\epsilon}{\sigma}\right)$$

$$2. \quad \frac{\epsilon}{\sigma} | \mathbf{X} \sim N(0, \mathbf{I}_n), \left(\frac{\epsilon}{\sigma}\right)' \mathbf{M} \left(\frac{\epsilon}{\sigma}\right) | \mathbf{X} \sim \chi_{rank(\mathbf{M})}^2$$

$$3. \quad rank(\mathbf{M}) = n - k$$

假设检验:

$$3. \quad \frac{b-\beta}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})^{-1}}} | \mathbf{X} \sim N(0, 1)$$

$$1. \quad \frac{b-\beta}{\sqrt{s^2(\mathbf{X}'\mathbf{X})^{-1}}} \sim t_{n-k}$$

$$1. \quad \frac{b-\beta}{\sqrt{s^2(\mathbf{X}'\mathbf{X})^{-1}}} = \frac{b-\beta}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})^{-1}}} / \frac{s}{\sigma} \sim \frac{N(0,1)}{\sqrt{\chi_{n-k}^2/n-k}}$$

$$4. \quad \mathbf{Rb} \sim N(\mathbf{R}\beta, \sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}')$$

$$1. \quad (\mathbf{Rb} - \mathbf{R}\beta)' (\sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}')^{-1} (\mathbf{Rb} - \mathbf{R}\beta) \sim \chi_{rank(\mathbf{R})}^2$$

$$2. \quad (\mathbf{Rb} - \mathbf{R}\beta)' (s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}')^{-1} (\mathbf{Rb} - \mathbf{R}\beta) / rank(\mathbf{R}) \sim F_{rank(\mathbf{R}), n-k} \\ (\mathbf{Rb} - \mathbf{R}\beta)' (s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}')^{-1} (\mathbf{Rb} - \mathbf{R}\beta) / rank(\mathbf{R})$$

$$1. \quad = \frac{(\mathbf{Rb} - \mathbf{R}\beta)' (\sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}')^{-1} (\mathbf{Rb} - \mathbf{R}\beta) / rank(\mathbf{R})}{s^2 / \sigma^2}$$

$$\sim [\chi_{rank(\mathbf{R})}^2 / rank(\mathbf{R})] / [\chi_{n-k}^2 / (n-k)]$$

## 大样本OLS(基于随机'DGP', 而非i.i.d随机样本)

### DGP介绍

DGP (数据生成过程), 或者称为STSP(随机时间序列过程), 数学上可以写作一个随机过程  $Z_t = Z(t, \omega)$ ,  $\omega \in \Omega$ , 这是一条关于时间  $t$  的数据路径, 具体值由  $\omega$  决定

### 模型所要研究的DGP

#### 平稳序列 stationary

##### 严平稳序列

**定义 5.2 [严平稳]:** 一个随机时间序列  $\{Z_t\}$  是严平稳的, 如果对于任意的不同时间点  $t_1, t_2, \dots, t_m$ , 以及对于任意的正整数  $k$  和  $m$ ,  $\{Z_{t_1}, Z_{t_2}, \dots, Z_{t_m}\}$  与  $\{Z_{t_1+k}, Z_{t_2+k}, \dots, Z_{t_m+k}\}$  具有相同的联合概率分布, 即

$$F_{Z_{t_1} Z_{t_2} \dots Z_{t_m}}(z_1, \dots, z_m) = F_{Z_{t_1+k} Z_{t_2+k} \dots Z_{t_m+k}}(z_1, \dots, z_m)$$

## 弱平稳(二阶平稳 协方差平稳)

对于一个随机时间序列 $\{Z_t\}$ , 若对任意 $t$ 满足以下条件则称为弱平稳

- (1)  $E(Z_t) = \mu$ 。
- (2)  $\text{var}(Z_t) = \sigma^2 < \infty$ 。
- (3)  $\text{cov}(Z_t, Z_{t-j}) = \gamma(j)$  仅是滞后阶数  $j$  的函数, 与时间点  $t$  无关。

## 遍历序列 ergodic

**定义 5.9 [遍历性 (Ergodicity)]:** 一个严平稳序列  $\{Z_t\}$  是遍历的, 如果对于任意两个有界函数  $f: \mathbb{R}^{k+1} \rightarrow \mathbb{R}$  和  $g: \mathbb{R}^{l+1} \rightarrow \mathbb{R}$ , 及任意正整数  $k, l$ , 有

$$\begin{aligned} \lim_{m \rightarrow \infty} |E[f(Z_t, \dots, Z_{t+k})g(Z_{m+t}, \dots, Z_{m+t+l})]| \\ = |E[f(Z_t, \dots, Z_{t+k})]| \cdot |E[g(Z_{m+t}, \dots, Z_{m+t+l})]| \end{aligned}$$

从随机过程角度理解:

“遍历性” = “不可约 非周期 正常返”

直观理解1:

对时间序列中任一时期取期望, 与对时间序列各时期取值求均值等价; 数据路径可以反映每一个时点的样本的数量特征。

直观理解2:

这意味着弱相关性: 只要时间间隔足够长, 时点间渐近独立

## 白噪声 white noise

**定义 5.5 [白噪声 (White Noise, WN)]:** 随机时间序列  $\{Z_t\}$  是白噪声 (或序列无关), 如果对所有  $t$ , 有

- (1)  $E(Z_t) = 0$ 。
- (2)  $\text{var}(Z_t) = \sigma^2$ 。
- (3)  $\text{cov}(Z_t, Z_{t-j}) = \gamma(j) = 0$ , 对所有的滞后阶  $j > 0$ 。

## 鞅 martingale

对于一个随机时间序列 $\{Z_t\}$ , 若对任意 $t$ 满足以下条件则称为鞅:

$E(Z_t | \sigma_{t-1}) = Z_{t-1}$   $\sigma_{t-1}$ 指的是前 $t-1$ 期所蕴含的全部信息

$\{\sigma_t\}$ 构成了一个递增的集合序列, 称为 $\sigma$ -域流

## 鞅差分序列 m.d.s

对于一个鞅 $\{Z_t\}$ , 做一阶差分可以生成一个新的随机时间序列 $\{\epsilon_t\}$ :

$$\epsilon_t = Z_t - Z_{t-1}$$

根据鞅的性质易得 $E(\epsilon_t | \sigma_{t-1}) = 0$ : 不可预测当期的中性的随机冲击

**引理 5.1** 如果  $\{\epsilon_t\}$  是一个鞅差分序列, 且  $E(\epsilon_t^2) = \sigma^2 < \infty$ , 则  $\{\epsilon_t\}$  是一个白噪声。

**证明** 由重复期望法则, 有

$$E(\epsilon_t) = E[E(\epsilon_t | I_{t-1})] = 0$$

且对于任意的  $j > 0$ , 有

$$\begin{aligned}\text{cov}(\epsilon_t, \epsilon_{t-j}) &= E(\epsilon_t \epsilon_{t-j}) - E(\epsilon_t)E(\epsilon_{t-j}) \\ &= E[E(\epsilon_t | I_{t-1}) \epsilon_{t-j}] \\ &= E(0 \cdot \epsilon_{t-j}) \\ &= 0\end{aligned}$$

这表明, 鞅差分序列是白噪声, 且方差  $\text{var}(\epsilon_t) = \sigma^2$ 。

## 一些实例

AR(1)

MA(1)

ARCH

## 针对DGP的LLN&CLT

### 遍历平稳随机序列的WLLN

**引理 5.2** [遍历平稳随机样本的弱大数定理 (WLLN for Ergodic Stationary Random Samples)]: 假设  $\{Z_t\}$  是一个遍历平稳过程, 并且  $E(Z_t) = \mu$ ,  $E|Z_t| < \infty$ 。则当  $n \rightarrow \infty$  时, 样本均值

$$\bar{Z}_n = n^{-1} \sum_{t=1}^n Z_t \xrightarrow{p} \mu$$



## 遍历平稳鞅差分序列的CLT

**定理 5.3** [遍历平稳鞅差分序列的中心极限定理 (CLT for Ergodic Stationary M.D.S)]: 假设  $\{Z_t\}$  是一个遍历平稳鞅差分序列,  $\text{var}(Z_t) \equiv E(Z_t Z_t') = V$  是有限、对称与正定的矩阵。则当  $n \rightarrow \infty$  时, 有

$$\sqrt{n}\bar{Z}_n = n^{-1/2} \sum_{t=1}^n Z_t \xrightarrow{d} N(\mathbf{0}, V)$$

或等价地

$$V^{-1/2} \sqrt{n}\bar{Z}_n \xrightarrow{d} N(\mathbf{0}, I)$$

$$\text{Var}(\sqrt{n}\bar{Z}_n) = E(\sqrt{n}\bar{Z}_n \cdot \sqrt{n}\bar{Z}_n')$$

$$= n^{-1} E\left(\sum_{t=1}^n Z_t \cdot \sum_{s=1}^n Z_s'\right)$$

$$= n^{-1} \sum_{t=1}^n \sum_{s=1}^n E(Z_t \cdot Z_s')$$

$$= n^{-1} \sum_{t=1}^n E(Z_t \cdot Z_t')$$

$$\{t \neq s \quad \text{e.g. } t > s : E(Z_t \cdot Z_s') = E(E(Z_t \cdot Z_s') | \sigma_s) = 0\}$$

$$= E(Z_t \cdot Z_t')$$

$$= V$$

# 模型假设

**假设 5.1 [遍历平稳性 (Ergodic Stationarity)]** :  $\{Y_t, X_t'\}$  是一个可观测的遍历平稳过程, 其中  $Y_t$  是一个随机变量,  $X_t$  是一个  $K \times 1$  随机向量。

**假设 5.2 [线性 (Linearity)]**:

$$Y_t = X_t' \beta^0 + \varepsilon_t$$

其中  $\beta^0$  是  $K \times 1$  未知参数向量,  $\varepsilon_t$  是不可观测的扰动项。

**假设 5.3 [正确模型设定 (Correct Model Specification)]**:  $E(\varepsilon_t | X_t) = 0$  且  $E(\varepsilon_t^2) = \sigma^2 < \infty$ .

**假设 5.4 [非奇异性 (Nonsingularity)]**:  $K \times K$  矩阵

$$Q = E(X_t X_t')$$

是有限、对称和非奇异的。

**假设 5.5 [鞅差分 (M.D.S)]**: 相对于  $\{X_s \varepsilon_s, s < t\}$  生成的  $\sigma$ -域,  $\{X_t \varepsilon_t\}$  为一鞅差分序列, 并且  $K \times K$  矩阵  $V \equiv \text{var}(X_t \varepsilon_t) = E(X_t X_t' \varepsilon_t^2)$  是有限、对称及正定的。

- 
0. 与[高计\(考完啦\) > 有限样本假设](#)相比假设4&5放松了, 但是对随机序列  $\{y_t, X_t\}$   $\{X_t \varepsilon_t\}$  增加了一些假设
  1. 假设3也称为前定条件, 这里有一个隐含假设: 存在常数项解释变量。一般情况下假设3表示为  $E(\mathbf{X}_t \varepsilon_t) = E(\mathbf{g}_t) = 0$ , 即  $t$  期解释变量在这一期之前已确定, 与当期随机扰动项“正交”
  2. 在接下来的记录中默认  $X_{t:k \times 1}$  (按时间) 为列向量。从而可以将随机矩阵记作:  $\mathbf{X} = (\mathbf{X}_1' \cdots \mathbf{X}_n')'$ ,  $\mathbf{X}' = (\mathbf{X}_1 \cdots \mathbf{X}_n)$
  3. 记  $g_t = X_t \varepsilon_t$   $\bar{g} = \sum g_t / n = \mathbf{X}' \varepsilon / n$   
 $\mathbf{S} = \text{Var}(\mathbf{g}_t)$   $\mathbf{S}_{xx} = \sum X_t \cdot X_t' / n$  ( $k \times k$  vec.)  
 $\mathbf{S}_{xy} = \sum X_t \cdot y_t / n$  ( $k \times 1$  vec.)

## OLS代数计算

由[高计\(考完啦\) > OLS代数计算](#)结果经过代数变换可以得到:

$$\begin{aligned}
b &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\mathbf{X}'\mathbf{X}/n)^{-1}\mathbf{X}'\mathbf{y}/n = \mathbf{S}_{xx}^{-1}\mathbf{S}_{xy} \\
b &= \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\epsilon = \beta + (\mathbf{X}'\mathbf{X}/n)^{-1}\mathbf{X}'\epsilon/n \\
&= \beta + \mathbf{S}_{xx}^{-1}\bar{\mathbf{g}}
\end{aligned}$$

基于这个式子可以得出  $\mathbf{S}_{xy}^{-1} = \mathbf{S}_{xx}\beta + \bar{\mathbf{g}}$

基于这个表达式得到的OLS渐近偏误可以解释内生性出现时偏误的方向。

## 大样本(渐近)OLS性质

help: [数理统计 > Slutsky引理](#)

示例:  $X_n \xrightarrow{\mathcal{D}} X, Y_n \xrightarrow{p} c$

### b的大样本性质

- $\bar{\mathbf{g}} \xrightarrow{P} \mathbf{0}$   
LLN+模型前定假设立即得到  
一般情况下, 渐近偏误依概率收敛到  $\Sigma_{xx}^{-1}E(\mathbf{g}_t)$
- $\mathbf{S}_{xx}^{-1} \xrightarrow{P} \Sigma_{xx}^{-1}$   
LLN+模型非奇异假设立即得到
- $\mathbf{b} \xrightarrow{P} \beta$   
 $\mathbf{b} - \beta = \mathbf{S}_{xx}^{-1}\bar{\mathbf{g}}: \bar{\mathbf{g}} \xrightarrow{p} E(\mathbf{g}) = \mathbf{0} \quad \mathbf{S}_{xx}^{-1} \xrightarrow{p} \Sigma_{xx}^{-1}$   
 $\mathbf{b} - \beta \xrightarrow{p} \mathbf{0} \quad \text{Q. E. D}$
- $\sqrt{n}\mathbf{S}_{xx}^{-1}\bar{\mathbf{g}} \xrightarrow{\mathcal{D}} X \sim N(0, Avar(\mathbf{b})) \quad Avar(\mathbf{b}) = \Sigma_{xx}^{-1}\mathbf{S}\Sigma_{xx}^{-1}$   
(  $\Sigma_{xx}^{-1} = E(\mathbf{X}'\mathbf{X}) \quad \mathbf{S} = E(\mathbf{g}\mathbf{g}') = E(\epsilon^2\mathbf{x}_i\mathbf{x}_i')$  )  
将左式拆分成两部分  $\sqrt{n}\mathbf{S}_{xx}^{-1}\bar{\mathbf{g}} = \mathbf{S}_{xx}^{-1} \cdot \sqrt{n}\bar{\mathbf{g}}$   
 $\sqrt{n}\bar{\mathbf{g}}$  依据 m. d. s 版本的 CLT 可以证明依分布收敛到  $N(0, Var(g_i) = S)$   
又因为  $\mathbf{S}_{xx}^{-1} \xrightarrow{P} \Sigma_{xx}^{-1}$ , 依据 Slutsky 定理, QED
- 补充命题: 对于参数  $\theta_0$  存在点估计  $\theta_n$  且  $\sqrt{n}(\theta_n - \theta_0) \xrightarrow{\mathcal{D}} N(\mu, \Sigma)$ ,  $\mu, \Sigma$  有界, 则点估计  $\theta_n$  是参数  $\theta_0$  的一致估计  
( $\theta_n - \theta_0$ )  $\xrightarrow{\mathcal{D}} N(\mu/n, \Sigma/n)$  RHS r. v. 依概率收敛到原点, QED

### $E(\epsilon^2)$ 的估计

至于此处为什么  $E(\epsilon^2)$  与  $Var(\epsilon)$  不等价在上面已经提及:

假设3也称为前定条件，这里有一个隐含假设：存在常数项解释变量。  
 一般情况下假设3表示为 $E(X_t \epsilon_t) = 0$ ，即 $t$ 期解释变量在这一期之前已确定，与当期随机扰动项“正交”

- $\frac{e'e}{n}$   $\frac{e'e}{n-k}$  都是一致估计  
 直观理解，后者本来就是无偏估计(更充分)，前者是后者的 $\frac{n-k}{n}$ 倍，倍数收敛到1，从而在渐近视角下(具体证明用Slutsky)二者都是一致估计  
 证明：

$$\begin{aligned} e &= Y - Xb = \epsilon - X(b - \beta) \\ e'e &= \epsilon'\epsilon + (b - \beta)'X'X(b - \beta) - (b - \beta)'X'\epsilon + \epsilon'X(b - \beta) \\ e'e/n &= \epsilon'\epsilon/n + (b - \beta)'(X'X/n)(b - \beta) - 2\bar{g}'(b - \beta) \end{aligned}$$

对最后一个式子利用LLN+上面的收敛性结论，QED

## 假设检验

- $H_0 : \beta_j = c$   
 如果 $H_0$ 正确， $\frac{\sqrt{n}(\mathbf{b}_j - c)}{\sqrt{Avar(\mathbf{b}_{jj})}} \sim N(0, 1)$  Test:  $\frac{\sqrt{n}(\mathbf{b}_j - c)}{\sqrt{\widehat{Avar}(\mathbf{b}_{jj})}} \xrightarrow{\mathcal{D}} N(0, 1)$   
 不同于有限样本，这里不存在估计效应，即检验统计量分布的扭曲  
 高计(考完啦) > 点估计的条件分布
- $H_0 : R\beta = r$   
 如果 $H_0$ 正确， $\frac{\sqrt{n}(R\mathbf{b} - r)}{\sqrt{RAvar(\mathbf{b})R'}} \sim N(0, 1)$   
 Test:  $n(R\mathbf{b} - r)'(\widehat{RAvar(\mathbf{b})R'})^{-1}(R\mathbf{b} - r) \xrightarrow{\mathcal{D}} \chi^2_{\#R}$   
 把上式视作正态r. vec. 的自我内积，从而好理解为什么是 $\chi^2$ 分布：  
 $\sqrt{n}'(R\mathbf{b} - r)'(\widehat{RAvar(\mathbf{b})R'})^{-1/2}'(\widehat{RAvar(\mathbf{b})R'})^{-1/2}\sqrt{n}(R\mathbf{b} - r)$

## $S = E(\mathbf{X}_i \mathbf{X}_i' \epsilon_i^2) = \Sigma_g$ 的估计

🦋 假设6:  $\mathbf{X}$ 的四阶矩存在，则有 $\hat{S} = \frac{\mathbf{X}'\mathbf{B}\mathbf{X}}{n} \xrightarrow{p} S$   $B = \text{diag} < e_i^2 >$

证明：只考虑存在一个解释变量，被估计量是 $E((x\epsilon)^2)$ ，估计量是 $\sum(ex)^2/n$

$$\begin{aligned}
e^2 &= \epsilon^2 + [(b - \beta)x]^2 - 2(b - \beta)x\epsilon \\
(ex)^2 &= (\epsilon x)^2 + [(b - \beta)x^2]^2 - 2(b - \beta)x^3\epsilon \\
\sum (ex)^2 &= \sum (\epsilon x)^2 + (b - \beta)^2 \sum x^4 - 2(b - \beta) \sum x^3\epsilon \\
\sum (ex)^2 / n &= (\sum (\epsilon x)^2 / n) + (b - \beta)^2 (\sum x^4 / n) - 2(b - \beta) \bar{g} (\sum x^3 \epsilon) \\
(E(x^3 \epsilon) = E(x^2 x \epsilon) &\leq E(x^4) E(x \epsilon)^2 = E(x^4) E(g^2) < \infty)
\end{aligned}$$

对最后一个式子利用LLN+上面的收敛性结论，QED

## GMM(基于内生性、工具变量主题)

### 内生性问题介绍

### 工具变量:回顾中级计量

[数据分析方法\(中级计量\)](#) 看这里就好了

## 模型假设

其实和CH2很像

这里一共有三类变量:1个被解释变量: $\mathbf{y}$  ; L个解释变量: $\mathbf{z}$  ; k个工具变量: $\mathbf{x}$

1. DGP:  $\mathbf{y}_i = \mathbf{z}_i' \delta + \epsilon_i$

这里对于解释变量 $\{\mathbf{z}_i\}$ 没有任何的约束，可以视为是对CH2假设的放宽

2.  $\{\mathbf{y}_i, \mathbf{z}_i, \mathbf{x}_i\}$ 是遍历平稳的随机序列

为了使用遍历平稳序列的LLN

3. 工具变量前定:  $E(\mathbf{x}_i \epsilon_i') = E(\mathbf{g}_i) = E(\mathbf{x}_i \mathbf{y}_i - \mathbf{x}_i \mathbf{z}_i' \delta) = \mathbf{0}$

这对应着工具变量的外生性

4.  $r(E(\mathbf{x}_i \mathbf{z}_i')) = r(\Sigma_{xz}) = L$

一方面保证了工具变量**至少是恰好识别的**

另一方面保证了工具变量与解释变量的**相关性**:存在一个(L×L)主子式大于零，即存在L个工具变量与L个解释变量相关。

5.  $\{\mathbf{g}_i\}$ 是一个二阶矩有限的m. d. s.

为了使用遍历平稳m. d. s. 的CLT

6.  $E((\mathbf{x}_{ik} \mathbf{z}_{il})^2)$ 有限: 有限四阶矩(相比之下第二章假设的是X的有限四阶矩)用来证明 $\mathbf{S} = E(\mathbf{X}_i \mathbf{X}_i' \epsilon_i^2)$ 的一致估计

## 恰好识别特例：矩估计(MM)

依据假设3给出的矩条件，经代数变形有： $E(\mathbf{x}_i \mathbf{y}_i) - E(\mathbf{x}_i \mathbf{z}_i') \delta = 0$

由于是恰好估计，依据假设4，矩阵 $E(\mathbf{x}_i \mathbf{z}_i')$ 可逆，从而 $\delta$ 存在显式解

$$\delta = (E(\mathbf{x}_i \mathbf{z}_i'))^{-1} E(\mathbf{x}_i \mathbf{y}_i) \rightarrow \hat{\delta} = \left( \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{z}_i' \right)^{-1} \left( \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{y}_i \right) = (\mathbf{S}_{xz})^{-1} (\mathbf{S}_{xy})$$

## 一般情形:GMM

如果矩阵 $E(\mathbf{x}_i \mathbf{z}_i')$ 不是方阵，那么 $\delta$ 无解，从而不可估计；所以我们只好退而求其次，去寻找一个 $\hat{\delta}$ 使得 $\mathbf{S}_{xy} - \mathbf{S}_{xz} \hat{\delta}$  尽可能接近 $\mathbf{0}$ ，所以我们要最小化

$\bar{\mathbf{g}} = \mathbf{S}_{xy} - \mathbf{S}_{xz} \hat{\delta}$  的模，然而在统计学中，我们允许不同维度的权重不等，这通过表示二次型的 $(K \times K)$ 矩阵 $\hat{\mathbf{W}}$ 来体现

## 代数计算

此时我们的优化问题是：

$$\max_{\hat{\delta}} (\mathbf{S}_{xy} - \mathbf{S}_{xz} \hat{\delta})' \hat{\mathbf{W}} (\mathbf{S}_{xy} - \mathbf{S}_{xz} \hat{\delta})$$

目标函数展开为： $\hat{\delta}' \mathbf{S}_{xz}' \hat{\mathbf{W}} \mathbf{S}_{xz} \hat{\delta} - 2 \mathbf{S}_{xy}' \hat{\mathbf{W}} \mathbf{S}_{xz} \hat{\delta} + \mathbf{S}_{xy}' \hat{\mathbf{W}} \mathbf{S}_{xy}$

经过求导可以得到： $\hat{\delta} = (\mathbf{S}_{xz}' \hat{\mathbf{W}} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \hat{\mathbf{W}} \mathbf{S}_{xy}$

此时 $\bar{\mathbf{g}} = \mathbf{S}_{xy} - \mathbf{S}_{xz} \hat{\delta} = (\mathbf{I}_k - \mathbf{S}_{xz} (\mathbf{S}_{xz}' \hat{\mathbf{W}} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \hat{\mathbf{W}}) \mathbf{S}_{xy}$

同时我们也可以带入 $\hat{\delta} = \mathbf{S}_{xz}^{-1} \mathbf{S}_{xy}$ 得到估计误差：

$$\hat{\delta} - \delta = (\mathbf{S}_{xz}' \hat{\mathbf{W}} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \hat{\mathbf{W}} \bar{\mathbf{g}}$$

## 2SLS的GMM表达形式

假设模型： $\mathbf{y}_i = \delta_1 + \delta_2 \mathbf{z}_{2i} + \delta_3 \mathbf{z}_{3i} + \epsilon_i$

- 第一阶段： $reg \quad \mathbf{z}_{2i} \sim \mathbf{x}_i, \mathbf{z}_{3i}$

定义矩阵 $\mathbf{X} = (\mathbf{1} | \mathbf{X}_1 | \mathbf{Z}_3)_{n \times 3}$   $\mathbf{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$

从而得到第一阶段拟合值 $\hat{\mathbf{Z}}_2 = \mathbf{P}_X \mathbf{Z}_2$

- 第二阶段： $reg \quad \mathbf{y}_i \sim \hat{\mathbf{z}}_{2i}, \mathbf{z}_{3i}$

定义矩阵 $\hat{\mathbf{Z}} = (\mathbf{1} : \hat{\mathbf{Z}}_2 : \mathbf{Z}_3)_{n \times 3} = \mathbf{P}_X (\mathbf{1} : \mathbf{Z}_2 : \mathbf{Z}_3)_{n \times 3}$

$$\delta_{2SLS} = (\hat{\mathbf{Z}}' \hat{\mathbf{Z}})^{-1} \hat{\mathbf{Z}}' \mathbf{y} = (\mathbf{Z}' \mathbf{P}_X \mathbf{Z})^{-1} \mathbf{Z}' \mathbf{P}_X \mathbf{y} = (\mathbf{S}_{xz}' \mathbf{S}_{xx}^{-1} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \mathbf{S}_{xx}^{-1} \mathbf{S}_{xy}$$

由此可以看出 $\hat{\mathbf{W}} = \mathbf{S}_{xx}^{-1}$  第一阶段OLS regressor的协方差阵

# 渐近统计性质

## GMM估计量的性质

1.  $\hat{\delta} \xrightarrow{p} \delta$

实际上就是  $\bar{\mathbf{g}} \xrightarrow{p} \mathbf{0}$ , 这个通过假设3和4很容易得到

2.  $\sqrt{n}(\hat{\delta} - \delta) \xrightarrow{d} N(0, Avar(\hat{\delta}))$

$$Avar(\delta) = (\Sigma'_{xz} \hat{\mathbf{W}} \Sigma_{xz})^{-1} \Sigma'_{xz} \hat{\mathbf{W}} \mathbf{S} \hat{\mathbf{W}} \Sigma_{xz} (\Sigma'_{xz} \hat{\mathbf{W}} \Sigma_{xz})^{-1}$$

实际上就是  $\sqrt{n}(\bar{\mathbf{g}}) \xrightarrow{d} N(0, \mathbf{S})$ , 这个通过假设3和5很容易得到

$$\widehat{Avar}(\hat{\delta}) = (\mathbf{S}_{xz}' \hat{\mathbf{W}} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \hat{\mathbf{W}} \hat{\mathbf{S}} \hat{\mathbf{W}} \mathbf{S}_{xz} (\mathbf{S}_{xz}' \hat{\mathbf{W}} \mathbf{S}_{xz})^{-1}$$

## GMM残差的性质

$$\frac{1}{n} \sum_{i=1}^n e_i^2 \xrightarrow{p} E(\epsilon^2) \quad e_i = y_i - \mathbf{z}_i' \hat{\delta}$$

$$\frac{1}{n} \sum_{i=1}^n e_i^2 = \frac{1}{n} \sum_{i=1}^n \epsilon_i^2 + (\delta - \hat{\delta})' \left( \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i \mathbf{z}_i' \right) (\delta - \hat{\delta}) - 2(\delta - \hat{\delta})' \left( \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i \epsilon_i' \right)$$

但是这里不能得出  $\sqrt{n}(\frac{1}{n} \sum_{i=1}^n e_i^2 - E(\epsilon^2)) \xrightarrow{d} N(0, Avar(\epsilon^2))$

$$\begin{aligned} \sqrt{n} \left( \frac{1}{n} \sum_{i=1}^n e_i^2 - E(\epsilon^2) \right) &= \sqrt{n} \left( \frac{1}{n} \sum_{i=1}^n \epsilon_i^2 - E(\epsilon^2) \right) \\ &\quad + (\delta - \hat{\delta})' \left( \sqrt{n} \left( \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i \mathbf{z}_i' \right) \right) (\delta - \hat{\delta}) \\ &\quad - 2\sqrt{n}(\delta - \hat{\delta})' \left( \left( \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i \epsilon_i' \right) \right) \end{aligned}$$

这里并没有条件保证  $((\frac{1}{n} \sum_{i=1}^n \mathbf{z}_i \epsilon_i'))$  的收敛性(相比之下在第二章, 我们有前定条件保证  $((\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \epsilon_i'))$  依概率收敛到0), 如果ta不依概率收敛到0, 那么最后一项不会依概率收敛到0.

## 基于GMM模型的假设检验

1.  $H_0 : \delta_j = c$  如果原假设成立:  $\sqrt{n}(\hat{\delta}_j - \delta_j) \xrightarrow{\mathcal{D}} N(0, Avar(\hat{\delta})_{jj})$

$$\frac{\sqrt{n}(\hat{\delta}_j - c)}{\sqrt{\widehat{Avar}(\hat{\delta})}} \xrightarrow{d} N(0, 1)$$

2.  $H_0 : \mathbf{R}\delta = \mathbf{r}$  如果原假设成立:  $\sqrt{n}(\mathbf{R}\hat{\delta} - \mathbf{r}) \xrightarrow{d} N(0, \mathbf{R}Avar(\hat{\delta})\mathbf{R}')$

$$n(\mathbf{R}\hat{\delta} - \mathbf{r})' (\widehat{\mathbf{R}Avar(\hat{\delta})\mathbf{R}'})^{-1} (\mathbf{R}\hat{\delta} - \mathbf{r}) \xrightarrow{\mathcal{D}} \chi^2_{\#r}$$



## $S = E(\mathbf{X}_i \mathbf{X}_i' \epsilon_i^2) = \Sigma_g$ 的估计

在假设6之下，类似于CH2，可以得出一致估计  $\hat{S} = \frac{1}{n} \sum_{i=1}^n e_i^2 (\mathbf{x}_i \mathbf{x}_i')$

我们仅证明  $K=L=1$  的情景，过程在AE.2

2. We wish to prove Proposition 3.4. To avoid inessential complications, consider the case where  $K = 1$  and  $L = 1$  so that  $\mathbf{x}_i$  and  $\mathbf{z}_i$  are scalars. So (3.5.5) becomes

$$\hat{\epsilon}_i^2 = \epsilon_i^2 - 2(\hat{\delta} - \delta) z_i \epsilon_i + (\hat{\delta} - \delta)^2 z_i^2,$$

and the  $\hat{S}$  in (3.5.10) becomes

$$\frac{1}{n} \sum_{i=1}^n x_i^2 \epsilon_i^2 - 2(\hat{\delta} - \delta) \frac{1}{n} \sum_{i=1}^n z_i x_i^2 \epsilon_i + (\hat{\delta} - \delta)^2 \frac{1}{n} \sum_{i=1}^n z_i^2 x_i^2. \quad (*)$$

- (a) Show: The first term on the RHS of (\*) converges in probability to  $S$  ( $\equiv E(x_i^2 \epsilon_i^2)$ ).
- (b) Use the Cauchy-Schwartz inequality

$$E(|X \cdot Y|) \leq \sqrt{E(X^2) \cdot E(Y^2)}$$

to show that  $E(z_i x_i^2 \epsilon_i)$  exists and is finite. **Hint:**  $z_i x_i^2 \epsilon_i$  is the product of  $x_i \epsilon_i$  and  $x_i z_i$ . Fact:  $E(x)$  exists and is finite if and only if  $E(|x|) < \infty$ . Where do we use Assumption 3.6?

- (c) Show that the second term on the RHS of (\*) converges to zero in probability.

AE2 (1) 由于  $\{x_i, \epsilon_i\}$  遍历平稳: 符合LLN条件, 从而对  $\frac{1}{n} \sum_{i=1}^n x_i^2 \epsilon_i^2$  有:  $\frac{1}{n} \sum_{i=1}^n x_i^2 \epsilon_i^2 \xrightarrow{P} E(x_i^2 \epsilon_i^2)$   
(2)  $E(z_i x_i^2 \epsilon_i) = E(z_i x_i)(x_i \epsilon_i) \leq \sqrt{E(z_i x_i)^2 E(x_i \epsilon_i)^2}$ , 由 Assumption 3.5 知  $E(x_i^2 \epsilon_i^2) < \infty$   
由 Assumption 3.6 知  $E(x_i z_i^2) < \infty$   $\therefore E(z_i x_i^2 \epsilon_i) < \infty$   
(3) 对第二项:  $\frac{1}{n} \sum_{i=1}^n z_i x_i^2 \epsilon_i \xrightarrow{P} E(z_i x_i^2 \epsilon_i) < \infty$ ,  $\hat{\delta} \xrightarrow{P} \delta$ , 从而第二项依概率收敛至0  
(4) 对第三项:  $\frac{1}{n} \sum_{i=1}^n z_i^2 x_i^2 \xrightarrow{P} E(z_i^2 x_i^2) < \infty$ ,  $\hat{\delta} \xrightarrow{P} \delta$ , 从而第三项依概率收敛至0

## 最优权重矩阵的选取

通过上面的计算，我们发现  $Avar(\hat{\delta})$  与  $\hat{W}$  相关，为了最高的估计准度，我们要选取  $\hat{W}$  使得  $Avar(\hat{\delta})$  最小。这里采用先猜后证的方式给出：猜  $\hat{W} = \hat{S}^{-1}$



$$\hat{\delta} = (\mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \mathbf{S}_{xy}$$

$$\widehat{Avar}(\hat{\delta}) = (\mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \hat{\mathbf{S}} \hat{\mathbf{S}}^{-1} \mathbf{S}_{xz} (\mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \mathbf{S}_{xz})^{-1} = (\mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \mathbf{S}_{xz})^{-1}$$

$$\widehat{Avar}(\hat{\delta}) \xrightarrow{p} (\boldsymbol{\Sigma}'_{xz} \mathbf{S}^{-1} \boldsymbol{\Sigma}_{xz})^{-1} = Avar(\hat{\delta})$$

证明过程在AE.3

3. We wish to prove the algebraic result (3.5.11). What needs to be proved is that  $\mathbf{A} - \mathbf{B}$  is positive semidefinite where

$$\mathbf{A} \equiv (\boldsymbol{\Sigma}'_{xz} \mathbf{W} \boldsymbol{\Sigma}_{xz})^{-1} \boldsymbol{\Sigma}'_{xz} \mathbf{W} \mathbf{S} \mathbf{W} \boldsymbol{\Sigma}_{xz} (\boldsymbol{\Sigma}'_{xz} \mathbf{W} \boldsymbol{\Sigma}_{xz})^{-1}$$

and

$$\mathbf{B} \equiv (\boldsymbol{\Sigma}'_{xz} \mathbf{S}^{-1} \boldsymbol{\Sigma}_{xz})^{-1}.$$

A result from matrix algebra states:

Let  $\mathbf{A}$  and  $\mathbf{B}$  be two positive definite and symmetric matrices.  $\mathbf{A} - \mathbf{B}$  is positive semidefinite if and only if  $\mathbf{B}^{-1} - \mathbf{A}^{-1}$  is positive semidefinite.

Therefore, what needs to be proved is that

$$\mathbf{Q} \equiv \boldsymbol{\Sigma}'_{xz} \mathbf{S}^{-1} \boldsymbol{\Sigma}_{xz} - \boldsymbol{\Sigma}'_{xz} \mathbf{W} \boldsymbol{\Sigma}_{xz} (\boldsymbol{\Sigma}'_{xz} \mathbf{W} \mathbf{S} \mathbf{W} \boldsymbol{\Sigma}_{xz})^{-1} \boldsymbol{\Sigma}'_{xz} \mathbf{W} \boldsymbol{\Sigma}_{xz}$$

is positive semidefinite.

- (a) Since  $\mathbf{S}$  ( $K \times K$ ) is positive definite, there exists a nonsingular  $K \times K$  matrix  $\mathbf{C}$  such that  $\mathbf{C}'\mathbf{C} = \mathbf{S}^{-1}$ . Verify that  $\mathbf{Q}$  can be written as

$$\mathbf{Q} = \mathbf{H}'\mathbf{M}_G\mathbf{H},$$

where

$$\mathbf{H} = \mathbf{C}\boldsymbol{\Sigma}_{xz}, \quad \mathbf{M}_G = \mathbf{I}_K - \mathbf{G}(\mathbf{G}'\mathbf{G})^{-1}\mathbf{G}', \quad \mathbf{G} = \mathbf{C}'^{-1}\mathbf{W}\boldsymbol{\Sigma}_{xz}.$$

**Hint:**  $\mathbf{C}^{-1}\mathbf{C}'^{-1} = \mathbf{S}$ .

- (b) Show that  $\mathbf{Q}$  is positive semidefinite. **Hint:** First show that  $\mathbf{M}_G$  is symmetric and idempotent. As you showed in Exercise 1, a symmetric and idempotent matrix is positive semidefinite.

$$\begin{aligned}
 \text{AE3 (1)} \quad Q &= (\bar{X}'_z C') (C \bar{X}_z) - \bar{X}'_z W \bar{X}_z (\bar{X}'_z W C^{-1} C^{-1} W \bar{X}_z)^{-1} \bar{X}'_z W \bar{X}_z \\
 &= (\bar{X}'_z C') (C \bar{X}_z) - (\bar{X}'_z C') C^{-1} W \bar{X}_z (\bar{X}'_z W C^{-1} C^{-1} W \bar{X}_z)^{-1} \bar{X}'_z W C^{-1} (C \bar{X}_z) \\
 &= H' (\bar{I}_k - G(G'G)^{-1}G') H = H' M_G H
 \end{aligned}$$

(2) 先证  $M_G$  对称、幂零 (idempotent):

$$M'_G = \bar{I}_k - G(G'G)^{-1}G' = \bar{I}_k - G(G'G)^{-1}G' = M_G$$

$$M_G M_G = \bar{I}_k - 2G(G'G)^{-1}G' + G(G'G)^{-1}G'G(G'G)^{-1}G' = \bar{I}_k - G(G'G)^{-1}G' = M_G$$

对这类矩阵, 性质  $x, x'Ax = x'A'Ax = (Ax)'Ax \geq 0$ ;  $A$  半正定

同理  $x'H'M_G Hx = x'H'M'_G M_G Hx = (M_G Hx)' M_G Hx \geq 0$ ;  $Q$  半正定

## 两阶段有效GMM

动机: 基于最优权重矩阵  $\hat{W} = \hat{S}^{-1}$ , 我们需要估计出  $\hat{S}^{-1}$ ; 这需要  $e_i$ ; 而为了得到  $e_i$  我们需要得到一致估计的  $\hat{\delta}$ , 从而我们可以先估计出  $\hat{\delta}$

1. 先用一些经典的  $\hat{W}$  入手得到一致估计  $\hat{\delta}$ , 从而得到  $\hat{S}^{-1}$   
比如取  $\hat{W} = S_{xx}^{-1}$  (2SLS)  $\hat{W} = I$  (无差异)
2. 利用第一步得到的  $\hat{S}^{-1}$  作为  $\hat{W}$  再做一次 GMM, 使得  $Avar(\hat{\delta})$  最小

## 基于GMM的IV外生性检验

动机: 通过计算残差向量到原点的“最小统计距离”判断, 因此, 我们选取最优权重矩阵  $\hat{W} = \hat{S}^{-1}$  得到  $J$ -statistic

$$J(\hat{\delta}, \hat{S}) = (\sqrt{n}\bar{g})' \hat{S}^{-1} (\sqrt{n}\bar{g}) \quad \sqrt{n}\bar{g} \xrightarrow{d} N(0, (S_{xz}' \hat{S}^{-1} S_{xz})^{-1})$$

如果假设 3.1-3.5 全部满足:  $J$ -statistic 的渐近分布是  $\chi^2_K$  (根据 Slutsky 引理), 但小样本分布是  $\chi^2_{K-L}$ , 受制于  $\hat{\delta}$  中  $L$  个等式的约束。这个统计量衡量了  $\hat{\delta}(\hat{S})$  对应的残差向量到原点的“最小统计距离”。如果这个数值过大, 那很有可能就是外生性条件被违反。

证明过程在 AE.5

5. (optional) Prove Proposition 3.6 by following the steps below.

(a) Show:  $\mathbf{g}_n(\hat{\delta}(\hat{\mathbf{S}}^{-1})) = \hat{\mathbf{B}} \bar{\mathbf{g}}$  where  $\hat{\mathbf{B}} \equiv \mathbf{I}_K - \mathbf{S}_{xz}(\mathbf{S}'_{xz} \hat{\mathbf{S}}^{-1} \mathbf{S}_{xz})^{-1} \mathbf{S}'_{xz} \hat{\mathbf{S}}^{-1}$ .

(b) Since  $\hat{\mathbf{S}}$  is positive definite, there exists a nonsingular  $K \times K$  matrix  $\mathbf{C}$  such that  $\mathbf{C}'\mathbf{C} = \hat{\mathbf{S}}^{-1}$ . Define  $\mathbf{A} \equiv \mathbf{C}\mathbf{S}_{xz}$ . Show that  $\hat{\mathbf{B}}'\hat{\mathbf{S}}^{-1}\hat{\mathbf{B}} = \mathbf{C}'\mathbf{M}\mathbf{C}$ , where  $\mathbf{M} \equiv \mathbf{I}_K - \mathbf{A}(\mathbf{A}'\mathbf{A})^{-1}\mathbf{A}'$ . What is the rank of  $\mathbf{M}$ ? **Hint:** The rank of an idempotent matrix equals its trace.

(c) Let  $\mathbf{v} \equiv \sqrt{n} \mathbf{C} \bar{\mathbf{g}}$ . Show that  $\mathbf{v} \rightarrow_d N(\mathbf{0}, \mathbf{I}_K)$ .

(d) Show that  $J(\hat{\delta}(\hat{\mathbf{S}}^{-1}), \hat{\mathbf{S}}^{-1}) = \mathbf{v}'\mathbf{M}\mathbf{v}$ . What is its asymptotic distribution?

$$AE5 (1) \mathbf{g}_n(\hat{\delta}(\hat{\mathbf{S}}^{-1})) = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i' (\mathbf{y}_i - \mathbf{z}_i' \hat{\delta}(\hat{\mathbf{S}}^{-1})) = \mathbf{S}_{xy} - \mathbf{S}_{xz} \hat{\delta}(\hat{\mathbf{S}}^{-1}) = (\mathbf{I}_K - \mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \mathbf{S}_{xy} = \hat{\mathbf{B}} \mathbf{S}_{xy}$$

$$\hat{\mathbf{B}} \mathbf{S}_{xy} = \hat{\mathbf{B}} \cdot \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i' (\mathbf{z}_i' \hat{\mathbf{S}}^{-1} + \varepsilon_i) = \hat{\mathbf{B}} \bar{\mathbf{g}} + \hat{\mathbf{B}} \mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1}$$

$$\hat{\mathbf{B}} \mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} = \mathbf{S}_{xz} \hat{\mathbf{S}}^{-1} - \mathbf{S}_{xz} (\mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \hat{\mathbf{S}}^{-1} \mathbf{S}_{xz} \hat{\mathbf{S}}^{-1} = \mathbf{S}_{xz} \hat{\mathbf{S}}^{-1} - \mathbf{S}_{xz} \hat{\mathbf{S}}^{-1} = \mathbf{0}$$

$$\therefore \hat{\mathbf{B}} \mathbf{S}_{xy} = \hat{\mathbf{B}} \bar{\mathbf{g}}$$

$$(2) \hat{\mathbf{B}}' \hat{\mathbf{S}}^{-1} \hat{\mathbf{B}} = (\mathbf{C} \hat{\mathbf{B}})' \mathbf{C} \hat{\mathbf{B}};$$

$$\mathbf{C} \hat{\mathbf{B}} = \mathbf{C} - \mathbf{C} \mathbf{S}_{xz} (\mathbf{S}_{xz}' \mathbf{C}' \mathbf{C} \mathbf{S}_{xz})^{-1} \mathbf{S}_{xz}' \mathbf{C}' \mathbf{C} = \mathbf{C} - \mathbf{A}(\mathbf{A}'\mathbf{A})^{-1} \mathbf{A}' \mathbf{C} = \mathbf{M} \mathbf{C}$$

$$\therefore (\mathbf{C} \hat{\mathbf{B}})' \mathbf{C} \hat{\mathbf{B}} = \mathbf{C}' \mathbf{M}' \mathbf{M} \mathbf{C}$$

$$\text{又因为 } \mathbf{M}'\mathbf{M} = (\mathbf{I}_K - \mathbf{A}(\mathbf{A}'\mathbf{A})^{-1} \mathbf{A}')' (\mathbf{I}_K - \mathbf{A}(\mathbf{A}'\mathbf{A})^{-1} \mathbf{A}') = \mathbf{I}_K - \mathbf{A}(\mathbf{A}'\mathbf{A})^{-1} \mathbf{A}'; \text{ 上式} = \mathbf{C}' \mathbf{M} \mathbf{C}$$

$$\text{由于 } \mathbf{M} \text{ 幂等: } \text{rank}(\mathbf{M}) = \text{tr}(\mathbf{M}) = K - \text{tr}(\mathbf{A}(\mathbf{A}'\mathbf{A})^{-1} \mathbf{A}') = K - \text{tr}(\mathbf{A}'\mathbf{A}(\mathbf{A}'\mathbf{A})^{-1}) = K - L$$

$$(3) \text{ 由于 } \sqrt{n} \bar{\mathbf{g}} \xrightarrow{d} N(\mathbf{0}, \mathbf{S}), \sqrt{n} \mathbf{C} \bar{\mathbf{g}} \xrightarrow{d} N(\mathbf{0}, \mathbf{C} \mathbf{S} \mathbf{C}'), \mathbf{C} \mathbf{S} \mathbf{C}' = \mathbf{C} (\mathbf{C}' \mathbf{C})^{-1} \mathbf{C}' = \mathbf{C} \mathbf{C}' \mathbf{C}'^{-1} \mathbf{C} = \mathbf{I}_K$$

$$(4) J(\hat{\delta}(\hat{\mathbf{S}}^{-1}), \hat{\mathbf{S}}^{-1}) = n (\hat{\mathbf{B}} \bar{\mathbf{g}})' \hat{\mathbf{S}}^{-1} (\hat{\mathbf{B}} \bar{\mathbf{g}}) = (\sqrt{n} \bar{\mathbf{g}})' \hat{\mathbf{B}}' \hat{\mathbf{S}}^{-1} \hat{\mathbf{B}} (\sqrt{n} \bar{\mathbf{g}}) = (\sqrt{n} \bar{\mathbf{g}})' \mathbf{C}' \mathbf{M} \mathbf{C} (\sqrt{n} \bar{\mathbf{g}})$$

$$= (\sqrt{n} \mathbf{C} \bar{\mathbf{g}})' \mathbf{M} (\sqrt{n} \mathbf{C} \bar{\mathbf{g}}), \text{ 由于 } \sqrt{n} \mathbf{C} \bar{\mathbf{g}} \xrightarrow{d} N(\mathbf{0}, \mathbf{I}_K), \mathbf{M} \text{ 为幂等矩阵,}$$

$$\text{所以 } J \xrightarrow{d} \chi^2_{K-L} = \text{rank}(\mathbf{M})$$

## 期末小抄记录内容

1. 三类模型的假设、结论 (平行)
2. 有限样本的几何性质
3. GMM的一些特殊性质 (有效GMM 两步GMM 2SLS GMM Hansen J-test)
4. 一些例题